Classificação de alvos proteicos a partir de descritores moleculares do ChEMBL com árvores de decisão

Bernan R. do Nascimento[1], Paulo E. R. Araujo[1], Thiago R. P. de Carvalho[1]

[1]Universidade Federal do Piauí (UFPI)
Programa de Pós-Graduação em Ciência da Computação – Teresina – PI – Brasil
PPGCC010 – Aprendizagem de Máquina (2026.2) – Prof. Vinicius Ponte Machado

bernanr7@gmail.com, pauloaraujo@ufpi.edu.br

thiago.rafael.pc@gmail.com

Abstract. *Predicting which protein target an active molecule acts on is an early step in drug discovery. We rebuild a dataset of 27,714 molecules active against four targets (EGFR, BACE1, DRD2 and HDAC1) from the ChEMBL 37 API and train a decision tree on five physicochemical descriptors and twelve counts taken from the SMILES string. With a grouped split, the SMILES counts raise accuracy from 0.77 to 0.89 (mean of 10 seeds). A random split overestimates accuracy by 1.3 to 4.1 points, because a quarter of the test molecules have a twin with identical descriptors in the training set.*

Resumo. *Prever em qual proteína-alvo uma molécula ativa age é uma etapa inicial da descoberta de fármacos. Reconstruímos pela API do ChEMBL 37 uma base de 27.714 moléculas ativas contra quatro alvos (EGFR, BACE1, DRD2 e HDAC1) e treinamos uma árvore de decisão com cinco descritores físico-químicos e doze contagens extraídas do texto SMILES. Com divisão agrupada, as contagens elevam a acurácia de 0,77 para 0,89 (média de 10 seeds). A divisão aleatória superestima o resultado em 1,3 a 4,1 pontos, pois um quarto das moléculas de teste tem uma gêmea com descritores idênticos no treino.*

1. Introdução

Na descoberta de fármacos, saber em qual proteína uma molécula atua ajuda a priorizar experimentos e a antecipar efeitos colaterais. Bancos abertos como o ChEMBL [Gaulton et al. 2012, Zdrazil et al. 2024] reúnem milhões de medições de potência, e com eles é possível treinar modelos que sugerem o alvo de uma molécula [Keiser et al. 2007].

Este trabalho trata uma versão controlada do problema: dada uma molécula que se sabe ativa contra exatamente uma de quatro proteínas (EGFR, quinase associada ao câncer de pulmão; BACE1, protease ligada ao Alzheimer; DRD2, receptor de dopamina alvo de antipsicóticos; e HDAC1, enzima epigenética estudada em oncologia), prever qual é. O modelo é uma árvore de decisão [Breiman et al. 1984], escolhida porque suas regras podem ser lidas e discutidas.

Três pontos tornam o problema menos trivial do que parece. Primeiro, o conjunto do Kaggle que inspirou o trabalho está incompleto e foi preciso reconstruí-lo do ChEMBL. Segundo, cinco descritores físico-químicos globais separam mal as classes.

Terceiro, muitas moléculas compartilham exatamente os mesmos descritores, o que contamina a avaliação se o teste for sorteado ao acaso. As contribuições são:

- uma base reconstruída do ChEMBL_37, com 27.714 moléculas de quatro alvos e curadoria documentada passo a passo;
- 12 atributos obtidos apenas contando caracteres do SMILES, sem biblioteca de química, que elevam a acurácia da árvore em 12 pontos sobre os descritores;
- uma avaliação com divisão agrupada e 10 seeds, que mede o quanto a divisão aleatória superestima o resultado (de 1,3 a 4,1 pontos) e situa a árvore entre um piso e um teto dados por modelos de referência.

O texto segue a ordem do trabalho: fundamentos, base e curadoria, análise exploratória, metodologia de modelagem, resultados, limitações e conclusão.

2. Fundamentação e trabalhos relacionados

Predição de alvos. Bancos como o ChEMBL [Gaulton et al. 2012, Zdrazil et al. 2024] reúnem medições de potência de moléculas contra alvos proteicos, e é com eles que se treinam modelos que sugerem a quais proteínas uma molécula se liga. Uma abordagem clássica compara conjuntos de ligantes por similaridade química e relaciona proteínas pela semelhança do que elas ligam, o que permitiu prever interações novas depois confirmadas em laboratório [Keiser et al. 2007]. Este trabalho segue outra linha, mais simples e interpretável: classificar a molécula a partir de atributos numéricos calculados dela.

Descritores e SMILES. A regra dos cinco de Lipinski [Lipinski et al. 2001] usa massa molecular, LogP e números de doadores e aceptores de ligação de hidrogênio para julgar se uma molécula tende a ser absorvida. A TPSA [Ertl et al. 2000] estima a área polar da molécula somando contribuições de fragmentos e se relaciona a absorção intestinal e à passagem pela barreira hematoencefálica. O SMILES [Weininger 1988] descreve a molécula como texto: letras são átomos, dígitos fecham anéis e parênteses abrem ramificações. Contar esses símbolos dá atributos de composição sem analisar a estrutura, ao custo de não enxergar subestruturas, como o grupo hidroxamato.

Árvores de decisão. O CART [Breiman et al. 1984] divide o espaço de atributos de forma recursiva, em cada nó escolhendo o limiar de um atributo que mais reduz a impureza (Gini ou entropia). Sem limite de profundidade, a árvore acerta todo o treino; a poda por custo-complexidade, controlada por α, corta ramos que pouco reduzem o erro e diminui o número de folhas. A vantagem é a legibilidade das regras. Como referência de desempenho usam-se conjuntos de árvores, como a Random Forest [Breiman 2001], mais precisos e menos interpretáveis.

Vazamento e validação. Vazamento de dados, quando informação do teste chega ao treino, é uma causa documentada de resultados superestimados em ciência baseada em aprendizado de máquina [Kapoor and Narayanan 2023]. Em química, a divisão aleatória já é conhecida por ser otimista; Sheridan [Sheridan 2013] mostra que separar treino e teste por data estima melhor o desempenho prospectivo. Aqui o vazamento é mais direto: moléculas distintas com os mesmos cinco descritores podem cair em lados opostos da divisão. Por isso o teste agrupa as linhas pela tupla de descritores (Seção 5.2).

3. Dados e curadoria

3.1. Base de partida

O trabalho partiu do conjunto *MultiTarget Bioactivity ChEMBL*, publicado no Kaggle [xjoannax88 2026]. O arquivo disponível, porém, não corresponde à descrição da própria página: tem 1.333 linhas em vez de 8.711, nenhuma molécula de EGFR, apenas duas de BACE1 e 95,5% das linhas em DRD2. A página também associa BACE1 ao identificador CHEMBL1987, que designa outra proteína; o correto é CHEMBL4822. Como as versões anteriores exigem login para download, a base foi reconstruída diretamente do ChEMBL.

3.2. Reconstrução a partir do ChEMBL

Os dados vêm da API REST do ChEMBL [Davies et al. 2015], um banco curado de moléculas bioativas [Gaulton et al. 2012, Zdrazil et al. 2024], na versão ChEMBL_37 (lançada em 01/05/2026, extração em 24/10/2026). Para cada um dos quatro alvos da Tabela 1 foram baixadas as medições de ensaios de ligação (`assay_type = B`) com relação exata (=) e pChEMBL preenchido. O pChEMBL é a potência padronizada pelo ChEMBL, $-\log_{10}$ da concentração molar de IC_{50}, K_i, K_d ou EC_{50}; o valor 6 equivale a 1 μM.

A Figura 1 resume a curadoria. As 58.736 medições brutas perdem 7.328 registros marcados pelo ChEMBL como duplicata potencial e 49 sem SMILES. As 51.359 restantes são agregadas pela mediana do pChEMBL em cada par molécula-alvo (37.424 pares). Mantêm-se os pares com pChEMBL ≥ 6 (27.798) e removem-se 42 moléculas ativas em mais de um alvo, cujo rótulo seria ambíguo. O resultado são 27.714 moléculas, uma por linha, com a proteína-alvo como classe.

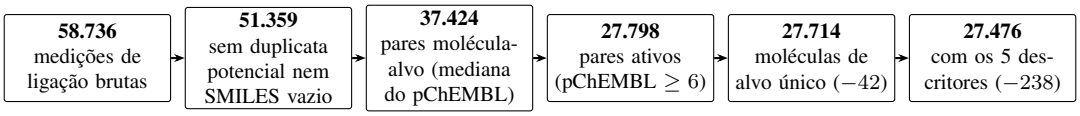


Figura 1. Funil de curadoria, do download à base de modelagem.

Cada molécula é descrita pelos cinco descritores que o ChEMBL calcula para a molécula parental, sem sal nem contraíon: massa molecular, LogP (ALogP), números de aceptores e doadores de ligação de hidrogênio (HBA e HBD) e área de superfície polar topológica (TPSA) [Ertl et al. 2000]. O pChEMBL não é usado como atributo, pois resulta do ensaio contra o próprio alvo e vazaria o rótulo. Nas 525 moléculas presentes também no arquivo do Kaggle, 99,6% têm o mesmo rótulo e 99,4% os mesmos descritores.

3.3. Problemas conhecidos

Há quatro ressalvas. (i) Em 238 moléculas (0,86%) faltam LogP, HBA, HBD e TPSA; são sobretudo peptídeos grandes (mediana de 1.103 Da), e essas linhas foram removidas, restando 27.476 para modelagem. (ii) 4.777 linhas repetem exatamente os cinco descritores de outra linha, sempre da mesma classe; isso causa o vazamento tratado na Seção 6.1. (iii) 182 moléculas passam de 1.000 Da. (iv) A base contém só moléculas ativas, então o modelo aprende a distinguir entre alvos, e não ativas de inativas.

Tabela 1. Classes da base final. A última coluna é a proporção das 27.714 moléculas.

Alvo	ChEMBL ID	Moléculas	%
EGFR	CHEMBL203	8.108	29,3
BACE1	CHEMBL4822	7.344	26,5
DRD2	CHEMBL217	6.650	24,0
HDAC1	CHEMBL325	5.612	20,2

O código, os notebooks e os dados estão em `https://github.com/pumba-dev/machine-learning-practice`. Os dados derivados do ChEMBL seguem a licença CC BY-SA 3.0.

4. Análise exploratória

As classes são razoavelmente balanceadas (Tabela 1): responder sempre EGFR, a majoritária, acerta 29,3%, e esse é o piso de comparação do restante do trabalho. A Figura 2 mostra os cinco descritores por alvo. DRD2 se destaca por TPSA e HBD baixos (mediana de 54,5 Å^2 e 1 doador, contra 98 a 101 Å^2 nos demais alvos), o que é compatível com ligantes de receptores cerebrais, em geral pouco polares. EGFR reúne as moléculas mais pesadas e lipofílicas (mediana de 497,6 Da e LogP de 4,6). HDAC1 tem o maior HBD (mediana 3), em linha com o grupo hidroxamato presente em muitos inibidores dessa enzima. BACE1 e HDAC1 se sobrepõem em massa, TPSA e HBA.

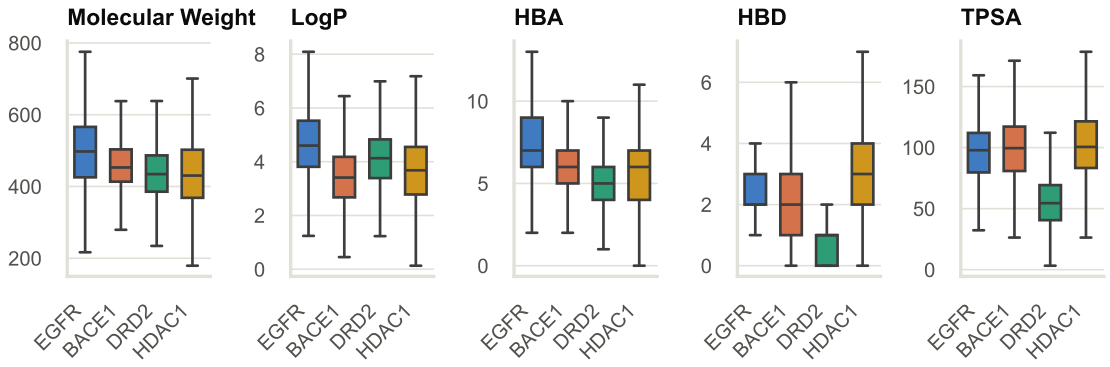


Figura 2. Descritores por proteína-alvo. Caixas mostram os quartis e as hastes 1,5 vez a amplitude interquartil; valores extremos foram omitidos.

TPSA, HBA e HBD são correlacionadas entre si (Spearman de 0,72 entre TPSA e HBA e de 0,69 entre TPSA e HBD), pois as três medem polaridade. Isso não prejudica a árvore, mas divide a importância entre elas. No plano LogP $\times$ TPSA (Figura 3), DRD2 se concentra em TPSA baixa e EGFR em LogP alto, enquanto BACE1 e HDAC1 ocupam a mesma região.

Nenhum descritor basta sozinho. Uma árvore de profundidade 3 treinada com uma única feature, em validação cruzada de 5 partes, atinge de 37,8% (massa molecular) a 45,1% (HBD): todas superam o piso de 29,3%, mas nenhuma passa de 45%. A árvore precisa combinar atributos, e o desempenho esperado com só cinco descritores globais é

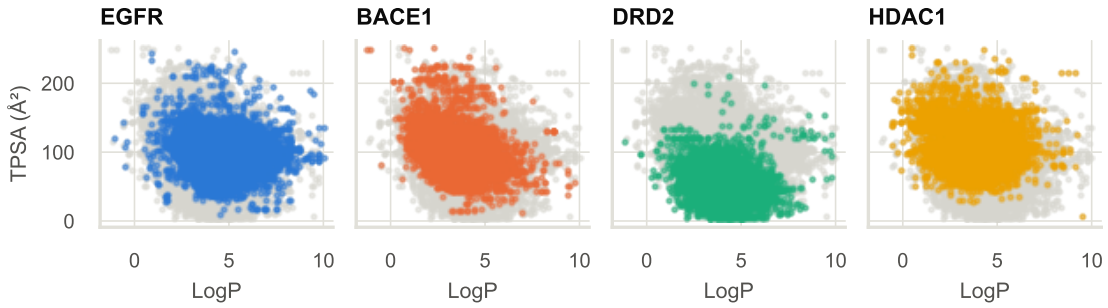


Figura 3. LogP × TPSA. Cada painel destaca uma classe sobre todas as moléculas (cinza).

limitado, sobretudo entre BACE1 e HDAC1. Isso motiva as features extraídas do SMILES (Seção 5).

5. Metodologia de modelagem

Tudo foi implementado em Python com scikit-learn [Pedregosa et al. 2011]. A tarefa é classificação multiclasse: prever a proteína-alvo (4 classes) das 27.476 moléculas com os cinco descritores completos.

5.1. Conjuntos de features

Além dos descritores, foram criadas 12 features por contagem de caracteres do SMILES, sem biblioteca de química: comprimento da cadeia; número de átomos de N, O e S; de halogênios (F, Cl, Br, I); de anéis (dígitos de fechamento dividido por 2); de ramificações (`(`); de átomos aromáticos (c, n, o, s minúsculos); de ligações duplas (`=`) e triplas (`#`); de cargas (`+`, `-`); e de marcas de estereoquímica (`@`, `/`). Cl e Br contam como um único símbolo, para que o "C" de Cl não seja contado como carbono. Comparam-se três conjuntos: os 5 descritores, as 12 contagens de SMILES e os 17 atributos juntos.

5.2. Divisão treino-teste e vazamento

Os dados são divididos em 80% para treino (21.980 moléculas) e 20% para teste (5.496), em dois esquemas. A divisão *aleatória* usa amostragem estratificada comum e ignora que linhas com descritores idênticos podem cair nos dois lados. A divisão *agrupada* usa o primeiro fold de um `StratifiedGroupKFold` de 5 partes, no qual todas as linhas com a mesma tupla dos cinco descritores formam um grupo que não é separado. As duas preservam a proporção das classes. A diferença entre elas mede o vazamento [Kapoor and Narayanan 2023], ou seja, o quanto o teste aleatório premia a memorização de moléculas quase idênticas às de treino.

5.3. Ajuste, avaliação e modelos de referência

Para cada um dos 6 cenários (3 conjuntos de features × 2 divisões), uma busca em grade com validação cruzada de 5 partes escolhe os hiperparâmetros da árvore de decisão: critério (`gini` ou `entropy`), profundidade máxima (8, 12, 16 ou sem limite), mínimo de amostras por folha (1, 5 ou 20) e parâmetro de poda por custo-complexidade α (0, 10^{-4} ou 3×10^{-4}), 72 combinações. A validação interna segue a mesma disciplina da divisão

externa: com treino agrupado, usa dobras agrupadas. A métrica de escolha é a acurácia. No teste, reportam-se acurácia, F1 macro (média simples do F1 das quatro classes), F1 por classe e a matriz de confusão.

Como piso e teto, usam-se no mesmo treino e teste um classificador que responde a classe majoritária, uma Random Forest de 300 árvores e um *gradient boosting* baseado em histogramas (`HistGradientBoosting`), ambos sem ajuste de hiperparâmetros.

5.4. Repetição com várias seeds

Um único split pode ser favorável ou desfavorável por acaso. Todo o procedimento acima é repetido com 10 seeds (0 a 9), que mudam as duas divisões, as dobras da validação cruzada e a semente dos modelos. As tabelas trazem média $\pm$ desvio padrão amostral. As curvas, a árvore desenhada e a análise de erros usam a seed 42, a mesma dos notebooks do projeto. A variação das seeds cobre o sorteio da divisão, mas não a escolha dos dados: a base é a mesma em todas as repetições.

6. Resultados e discussão

Salvo indicação em contrário, os números são média $\pm$ desvio padrão em 10 seeds (Seção 5); as figuras e os exemplos de erro usam a seed 42.

6.1. Vazamento por descritores repetidos

Das 27.476 moléculas, 22.699 têm uma tupla de descritores distinta e 4.777 repetem a de outra molécula (o maior grupo tem 12). Nenhum grupo mistura classes. No split aleatório, 25,8 $\pm$ 0,4% das moléculas de teste têm uma gêmea de descritores no treino. O efeito aparece na última coluna da Tabela 2: com só os cinco descritores, o split aleatório superestima a acurácia em 4,1 $\pm$ 0,9 pontos, pois a árvore pode decorar as gêmeas. Com as contagens de SMILES o excesso cai para 1,3 a 1,4 ponto, porque moléculas com os mesmos descritores têm SMILES diferentes e as contagens não são copiadas junto. A partir daqui, usa-se o split agrupado.

Tabela 2. Árvore de decisão no teste, por conjunto de atributos (média $\pm$ desvio em 10 seeds). Superestimativa é a acurácia aleatória menos a agrupada, em pontos percentuais.

Atributos	Acurácia aleatória	Acurácia agrupada	F1 macro agrupado	Superestimativa (pontos)
Descritores (5)	0,812 $\pm$ 0,005	0,771 $\pm$ 0,008	0,770 $\pm$ 0,008	4,1 $\pm$ 0,9
SMILES (12)	0,889 $\pm$ 0,004	0,876 $\pm$ 0,006	0,873 $\pm$ 0,006	1,3 $\pm$ 0,9
Ambos (17)	0,908 $\pm$ 0,003	0,894 $\pm$ 0,004	0,893 $\pm$ 0,004	1,4 $\pm$ 0,4

6.2. Efeito das features de SMILES

No split agrupado, os cinco descritores dão acurácia de 0,771 $\pm$ 0,008. As 12 contagens de SMILES sozinhas chegam a 0,876 $\pm$ 0,006, e os 17 atributos juntos a 0,894 $\pm$ 0,004 (F1 macro de 0,893 $\pm$ 0,004): um ganho de 12 pontos sobre os descritores, muito acima do desvio entre seeds. Contar letras de uma cadeia de texto carrega mais informação sobre a molécula, como número de anéis aromáticos e de halogênios, do que cinco propriedades globais. Na seed 42, a árvore escolhida acerta 0,897, dentro da faixa de 0,886 a 0,899 observada nas 10 seeds.

6.3. Profundidade, poda e quantidade de dados

A busca em grade escolheu `entropy` e nenhum limite de profundidade nos seis cenários, e só ativou a poda quando os atributos eram apenas os descritores: com cerca de 22 mil linhas de treino, a regra de parada da própria árvore já fica perto do ideal. A Figura 4a mostra o motivo. A acurácia de treino chega a 100% na profundidade 25, enquanto a de validação estaciona em torno de 0,87 a partir da profundidade 16. A poda por custo-complexidade (Figura 4b) reduz a árvore de 2.054 para 899 folhas com $\alpha = 10^{-4}$ sem perder acurácia de validação (0,870 para 0,872); acima de 10^{-3} a poda passa a custar acurácia, e com $\alpha = 10^{-2}$ sobram 8 folhas e 0,665.

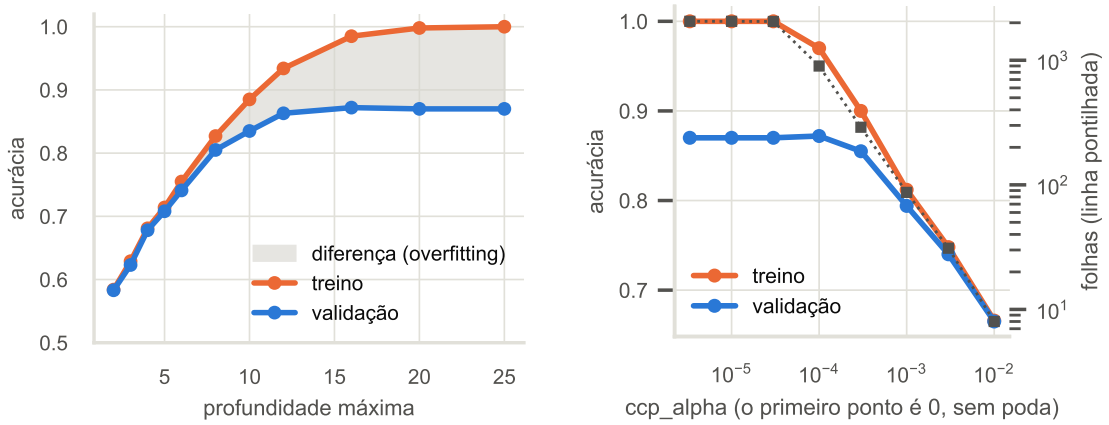


Figura 4. Acurácia de treino e de validação (seed 42, split agrupado, 17 atributos). (a) Por profundidade máxima. (b) Por α da poda, com o número de folhas na escala da direita (linha pontilhada); o primeiro ponto é $\alpha = 0$.

6.4. O que a árvore aprendeu

A árvore escolhida tem 1.854 folhas e 24 níveis, grande demais para ser desenhada. As primeiras camadas, porém, são legíveis. A raiz divide por TPSA ($\leq 67{,}9$ Å^2) e o ramo de TPSA baixa tem 69% de DRD2, como a análise exploratória antecipava. Em seguida vem `n_aromatic`, uma contagem de SMILES, e depois HBD, `n_rings`, `smiles_len` e `n_halogen`. Descritores e contagens se misturam já no topo. A Figura 5 confirma o quadro: TPSA e `n_aromatic` lideram nas duas medidas de importância, seguidas por HBD e por um bloco de contagens (`n_N`, `n_halogen`, `n_stereo`, `n_rings`) acima de LogP e HBA. A importância por permutação, medida no teste, dá mais peso às contagens do que a de impureza.

6.5. Erros e limites da árvore

Entre as classes, BACE1 e DRD2 são as mais fáceis (F1 de 0,909 e 0,904), seguidas de EGFR (0,892) e HDAC1 (0,866), a mais difícil. Na seed 42, o par HDAC1 $\leftrightarrow$ EGFR, nos dois sentidos, soma 28,7% dos 568 erros (Figura 6a), e 7,9% das moléculas de HDAC1 viram EGFR. Os erros não ocupam uma região do espaço de atributos: nenhuma das 17 features desloca a mediana entre acertos e erros em mais de meio intervalo interquartil. Entre seis exemplos de HDAC1 lidos como EGFR, dois têm o grupo hidroxamato `C(=O)NO`, típico de inibidores de HDAC. A árvore não o vê: contagens de caracteres dizem quantos oxigênios e nitrogênios existem, mas não como se ligam.

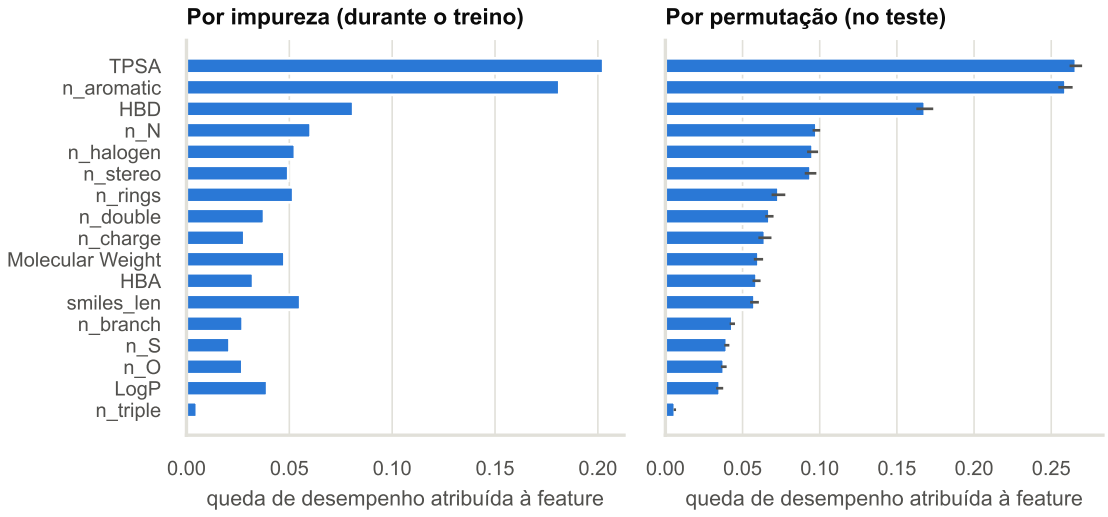


Figura 5. Importância dos atributos da árvore escolhida (seed 42): redução de impureza no treino e queda de acurácia por permutação no teste.

A árvore também não sabe quando erra. Sem poda, toda folha é pura, então `predict_proba` devolve 100% para as 5.496 previsões de teste, embora 10,3% estejam erradas. A curva de aprendizado (Figura 6b) mostra a outra limitação: o treino fica em 100% e a validação sobe de 0,615 (879 linhas) para 0,870 (17.584) sem se achatar, de modo que mais moléculas provavelmente renderiam mais acurácia.

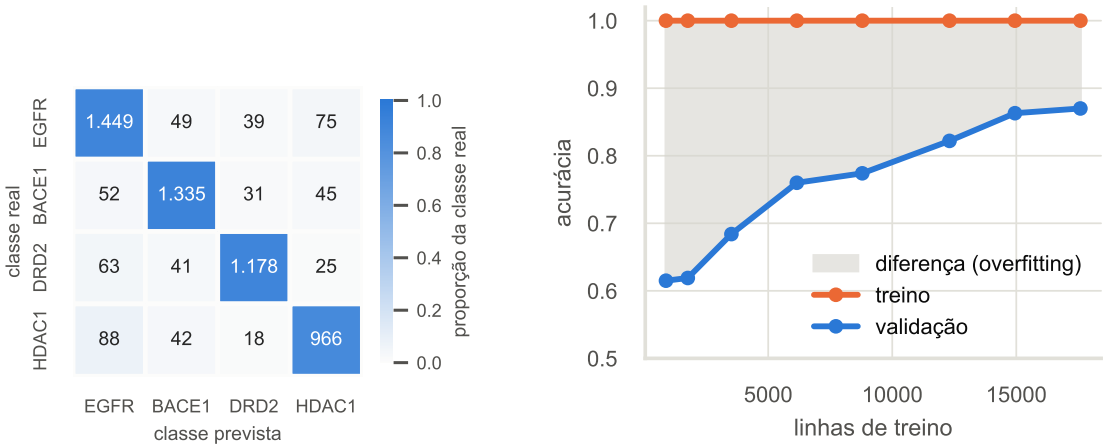


Figura 6. Seed 42, split agrupado, 17 atributos. (a) Matriz de confusão no teste: cor pela proporção da classe real, número em contagem. (b) Curva de aprendizado: acurácia por tamanho do conjunto de treino.

6.6. Comparação com modelos de referência

A Tabela 3 situa a árvore entre um piso e um teto. Responder a classe majoritária dá 0,293. A Random Forest [Breiman 2001] chega a 0,952 $\pm$ 0,003 e o *boosting* a 0,948 $\pm$ 0,003, cerca de 6 pontos acima da árvore única, que acerta 0,894 $\pm$ 0,004. Esses pontos são o preço da interpretabilidade: a árvore responde por que uma molécula foi classificada como

DRD2 com um caminho de perguntas sobre TPSA e contagens, enquanto os conjuntos não têm regras legíveis.

Tabela 3. Árvore e modelos de referência no split agrupado, com os 17 atributos (média ± desvio em 10 seeds).

Modelo	Acurácia	F1 macro
Classe majoritária	0,293 ± 0,000	0,113 ± 0,000
Árvore de decisão	0,894 ± 0,004	0,893 ± 0,004
Random Forest (300 árvores)	0,952 ± 0,003	0,951 ± 0,003
HistGradientBoosting	0,948 ± 0,003	0,947 ± 0,003

7. Limitações

O agrupamento por descritores idênticos não cobre séries químicas inteiras: análogos de um mesmo artigo continuam espalhados entre treino e teste, e as contagens de SMILES permitem decorar famílias estruturais. Dividir por esqueleto molecular controlaria isso, mas exige uma biblioteca de química. Por isso 0,894 ainda é otimista para moléculas realmente novas.

A base contém só moléculas ativas, então o modelo distingue um alvo de outro, não uma molécula ativa de uma inativa. As 10 seeds variam o sorteio da divisão, mas os dados são os mesmos, de modo que o desvio padrão não mede a incerteza para dados novos, e não há validação externa. A Random Forest e o *boosting* usam hiperparâmetros padrão, e o teto que representam pode estar subestimado. Por fim, as 238 moléculas sem descritores (0,86%) foram descartadas, em sua maioria muito grandes, e as probabilidades da árvore não são calibradas.

8. Conclusão e trabalhos futuros

Reconstruímos do ChEMBL_37 uma base de 27.714 moléculas ativas contra EGFR, BACE1, DRD2 e HDAC1 e treinamos uma árvore de decisão para prever o alvo. Com divisão agrupada, os cinco descritores físico-químicos dão acurácia de 0,771; acrescentar 12 contagens de caracteres do SMILES a leva a 0,894 ± 0,004, e as contagens sozinhas já chegam a 0,876. A divisão aleatória superestima o resultado em 1,3 a 4,1 pontos porque cerca de um quarto das moléculas de teste tem gêmea de descritores no treino. TPSA e o número de átomos aromáticos são os atributos mais importantes, e o par HDAC1–EGFR concentra 28,7% dos erros. A Random Forest chega a 0,952, cerca de 6 pontos acima da árvore, que em troca oferece regras legíveis.

Quatro caminhos seguem do que foi visto. Fingerprints estruturais, calculados com uma biblioteca de química, enxergariam subestruturas como o hidroxamato, que as contagens não veem. Uma divisão por esqueleto molecular daria uma estimativa menos otimista para moléculas novas. A curva de aprendizado ainda sobe, o que sugere buscar mais dados no ChEMBL, com outros alvos ou um limiar de atividade mais frouxo. Por fim, podar a árvore ou usar um conjunto de árvores daria probabilidades calibradas, e incluir moléculas inativas faria o modelo servir também à triagem.

Referências

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth International Group, Belmont, CA.

Davies, M., Nowotka, M., Papadatos, G., Dedman, N., Gaulton, A., Atkinson, F., Bellis, L., and Overington, J. P. (2015). ChEMBL web services: streamlining access to drug discovery data and utilities. *Nucleic Acids Research*, 43(W1):W612–W620.

Ertl, P., Rohde, B., and Selzer, P. (2000). Fast calculation of molecular polar surface area as a sum of fragment-based contributions and its application to the prediction of drug transport properties. *Journal of Medicinal Chemistry*, 43:3714–3717.

Gaulton, A. et al. (2012). ChEMBL: a large-scale bioactivity database for drug discovery. *Nucleic Acids Research*, 40(D1):D1100–D1107.

Kapoor, S. and Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804.

Keiser, M. J., Roth, B. L., Armbruster, B. N., Ernsberger, P., Irwin, J. J., and Shoichet, B. K. (2007). Relating protein pharmacology by ligand chemistry. *Nature Biotechnology*, 25(2):197–206.

Lipinski, C. A., Lombardo, F., Dominy, B. W., and Feeney, P. J. (2001). Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. *Advanced Drug Delivery Reviews*, 46(1–3):3–26.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Sheridan, R. P. (2013). Time-split cross-validation as a method for estimating the goodness of prospective prediction. *Journal of Chemical Information and Modeling*, 53(4):783–790.

Weininger, D. (1988). SMILES, a chemical language and information system. 1. introduction to methodology and encoding rules. *Journal of Chemical Information and Computer Sciences*, 28(1):31–36.

xjoannax88 (2026). MultiTarget Bioactivity ChEMBL. Kaggle, versão 17. `https://www.kaggle.com/datasets/xjoannax88/multitarget-bioactivity-chembl`.

Zdrazil, B. et al. (2024). The ChEMBL database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods. *Nucleic Acids Research*, 52(D1):D1180–D1192.