Classificação de alvos proteicos a partir de descritores moleculares do ChEMBL com árvores de decisão

Bernan R. do Nascimento[1], **Paulo E. R. Araujo**[1], **Thiago R. P. de Carvalho**[1]

[1]Universidade Federal do Piauí (UFPI)
Programa de Pós-Graduação em Ciência da Computação – Teresina – PI – Brasil
PPGCC010 – Aprendizagem de Máquina (2026.2) – Prof. Vinicius Ponte Machado

bernanr7@gmail.com, pauloaraujo@ufpi.edu.br

thiago.rafael.pc@gmail.com

Abstract. *Predicting which protein target a molecule is associated with is an early step in drug discovery. We rebuild from the ChEMBL 37 API a dataset of 27,714 molecules, each associated with one of four targets (EGFR, BACE1, DRD2 and HDAC1), and train a decision tree on five physicochemical descriptors and twelve counts taken from the SMILES string, a text that describes a molecule's structure. With a grouped split, the SMILES counts raise accuracy from 77.1% to 89.4% (a 16% relative gain; mean of 10 seeds). A random split overestimates accuracy by up to 5.3%, because a quarter of the test molecules have a twin with identical descriptors in the training set; the grouped split keeps such twins on the same side. Weka's Random Tree, which samples the features tried at each node, falls 0.4% below the decision tree, while tree ensembles gain 6.0% to 8.1%: feature sampling hurts a single tree but, across 300 trees, it is what makes the Random Forest work.*

Resumo. *Prever a qual proteína-alvo uma molécula está associada é uma etapa inicial da descoberta de fármacos. Reconstruímos pela API do ChEMBL 37 uma base de 27.714 moléculas, cada uma associada a um de quatro alvos (EGFR, BACE1, DRD2 e HDAC1), e treinamos uma árvore de decisão com cinco descritores físico-químicos e doze contagens extraídas do SMILES, texto que descreve a estrutura da molécula. Com divisão agrupada, as contagens elevam a acurácia de 77,1% para 89,4% (ganho relativo de 16%; média de 10 seeds). A divisão aleatória superestima o resultado em até 5,3%, pois um quarto das moléculas de teste tem uma gêmea de descritores idênticos no treino; a divisão agrupada mantém essas gêmeas do mesmo lado. A Random Tree do Weka, que sorteia os atributos de cada nó, fica 0,4% abaixo da árvore, enquanto conjuntos de árvores ganham de 6,0% a 8,1%: o sorteio de atributos piora uma árvore sozinha, mas, somado em 300 árvores, é o que faz a Random Forest funcionar.*

1. Introdução

Na descoberta de fármacos, saber a qual proteína uma molécula está associada ajuda a priorizar experimentos. Bancos abertos como o ChEMBL [Gaulton et al. 2012, Zdrazil et al. 2024] reúnem milhões de medições de potência de moléculas contra proteínas, e com eles é possível treinar modelos que sugerem o alvo de uma molécula [Keiser et al. 2007].

Este trabalho trata uma versão controlada do problema: dada uma molécula associada a exatamente uma de quatro proteínas (EGFR, BACE1, DRD2 e HDAC1), prever qual é. A molécula é descrita por números calculados a partir dela: cinco descritores físico-químicos e contagens extraídas do SMILES, um texto que descreve a estrutura da molécula. O modelo principal é uma árvore de decisão [Breiman et al. 1984], escolhida porque suas regras podem ser lidas e discutidas. Depois, ela é comparada com a Random Tree, uma árvore que sorteia os atributos de cada nó, e com conjuntos de árvores.

Três pontos tornam o problema menos trivial do que parece. Primeiro, o conjunto do Kaggle que inspirou o trabalho está incompleto e foi preciso reconstruí-lo do ChEMBL. Segundo, cinco descritores globais separam mal as classes. Terceiro, muitas moléculas compartilham exatamente os mesmos descritores: se uma cai no treino e outra no teste, o modelo é premiado por memorizar. Por isso comparamos a divisão aleatória, que sorteia as moléculas livremente, com a divisão agrupada, que mantém do mesmo lado as moléculas de descritores idênticos (Seção 5.2). As contribuições são:

- uma base reconstruída do ChEMBL_37, com 27.714 moléculas de quatro alvos e curadoria documentada passo a passo;
- 12 atributos obtidos apenas contando caracteres do SMILES, que, somados aos descritores, elevam a acurácia da árvore em 16% (ganho relativo);
- uma avaliação com divisão agrupada e 10 seeds, que mede o quanto a divisão aleatória superestima o resultado (de 1,5% a 5,3%, em termos relativos);
- uma comparação da árvore com a Random Tree do Weka, a Random Forest e o *gradient boosting*, que mostra por que o sorteio de atributos, que piora uma árvore sozinha, é a peça da Random Forest.

2. Fundamentação e trabalhos relacionados

Predição de alvos. Bancos como o ChEMBL [Gaulton et al. 2012, Zdrazil et al. 2024] reúnem medições de potência de moléculas contra alvos proteicos. Uma abordagem clássica para sugerir o alvo de uma molécula compara conjuntos de moléculas por similaridade química e relaciona proteínas pela semelhança do que elas ligam, o que permitiu prever interações novas depois confirmadas em laboratório [Keiser et al. 2007]. Este trabalho segue outra linha, mais simples e interpretável: classificar a molécula a partir de atributos numéricos calculados dela.

Descritores e SMILES. A regra dos cinco de Lipinski [Lipinski et al. 2001] usa massa molecular, LogP e os números de doadores e aceptores de ligação de hidrogênio, propriedades calculadas direto da estrutura da molécula. A TPSA [Ertl et al. 2000] é a área polar da molécula, estimada somando contribuições de fragmentos. O SMILES [Weininger 1988] descreve a molécula como texto: letras são átomos, dígitos fecham anéis e parênteses abrem ramificações. Contar esses símbolos dá atributos de composição sem analisar a estrutura, ao custo de não enxergar subestruturas, isto é, como os átomos estão ligados entre si.

Árvores de decisão. O CART [Breiman et al. 1984] divide o espaço de atributos de forma recursiva, em cada nó escolhendo o limiar de um atributo que mais reduz a impureza (Gini ou entropia). Sem limite de profundidade, a árvore acerta todo o treino; a poda por custo-complexidade, controlada por α, corta ramos que pouco reduzem o erro e diminui o número de folhas. A vantagem é a legibilidade das regras.

Random Tree e conjuntos de árvores. A Random Tree do Weka [Witten et al. 2016] é uma árvore única que, em cada nó, sorteia K dos n atributos e procura o melhor corte só entre eles; o padrão é $K = \lfloor \log_2 n \rfloor + 1$, sem poda. Sozinha, ela é uma árvore pior, porque o sorteio pode esconder o melhor corte. O sorteio existe para os conjuntos. A Random Forest [Breiman 2001] treina muitas árvores com sorteio de atributos em cada nó, cada uma numa amostra com reposição do treino (*bootstrap*), e a previsão é a média dos votos; o sorteio torna as árvores menos parecidas entre si e a média mais eficaz. O *gradient boosting* [Friedman 2001] também soma árvores, mas em sequência: cada árvore nova corrige o erro que as anteriores ainda cometem. A versão por histogramas [Ke et al. 2017] agrupa cada atributo em faixas antes de procurar cortes, o que acelera o treino. Os conjuntos costumam ser mais precisos que uma árvore única, ao custo de não terem regras legíveis.

Vazamento e validação. Vazamento de dados, quando informação do teste chega ao treino, é uma causa documentada de resultados superestimados em ciência baseada em aprendizado de máquina [Kapoor and Narayanan 2023]. Em química, a divisão aleatória já é conhecida por ser otimista; Sheridan [Sheridan 2013] mostra que separar treino e teste por data estima melhor o desempenho prospectivo. Aqui o vazamento é mais direto: moléculas distintas com os mesmos cinco descritores podem cair em lados opostos da divisão. Por isso o teste agrupa as moléculas pela tupla de descritores (Seção 5.2).

3. Dados e curadoria

3.1. Base de partida

O trabalho partiu do conjunto *MultiTarget Bioactivity ChEMBL*, publicado no Kaggle [xjoannax88 2026]. O arquivo disponível, porém, não corresponde à descrição da própria página: tem 1.333 linhas em vez de 8.711, nenhuma molécula de EGFR, apenas duas de BACE1 e 95,5% das linhas em DRD2. A página também associa BACE1 ao identificador CHEMBL1987, que designa outra proteína; o correto é CHEMBL4822. Como as versões anteriores exigem login para download, a base foi reconstruída diretamente do ChEMBL.

3.2. Reconstrução a partir do ChEMBL

Os dados vêm da API REST do ChEMBL [Davies et al. 2015], um banco curado de moléculas e de suas medições de potência [Gaulton et al. 2012, Zdrazil et al. 2024], na versão ChEMBL_37 (lançada em 01/05/2026, extração em 24/10/2026). Para cada um dos quatro alvos da Tabela 1 foram baixadas as medições de ensaios de ligação com valor exato (sem desigualdades) e com pChEMBL preenchido. O pChEMBL é uma medida de potência padronizada pelo ChEMBL ($-\log_{10}$ de uma concentração molar): quanto maior, mais potente a molécula contra o alvo. Neste trabalho, uma molécula é associada a um alvo quando seu pChEMBL contra ele é de pelo menos 6, o que equivale a 1 μM.

A Figura 1 resume a curadoria. As 58.736 medições brutas perdem 7.328 registros marcados pelo ChEMBL como duplicata potencial e 49 sem SMILES. As 51.359 restantes são agregadas pela mediana do pChEMBL em cada par molécula-alvo (37.424 pares). Mantêm-se os pares com pChEMBL ≥ 6 (27.798) e removem-se 42 moléculas associadas a mais de um alvo, cujo rótulo seria ambíguo. O resultado são 27.714 moléculas, uma por linha, com a proteína-alvo como classe.

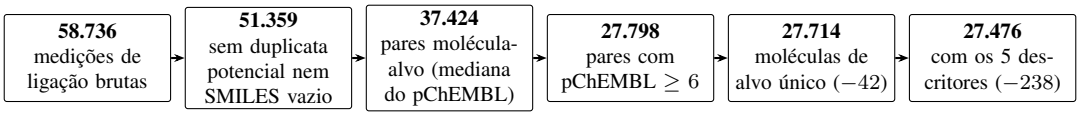


Figura 1. Funil de curadoria, do download à base de modelagem.

Cada molécula é descrita pelos cinco descritores que o ChEMBL calcula para ela: massa molecular, LogP, números de aceptores e doadores de ligação de hidrogênio (HBA e HBD) e área de superfície polar topológica (TPSA) [Ertl et al. 2000]. O pChEMBL não é usado como atributo, pois resulta do ensaio contra o próprio alvo e vazaria o rótulo. Nas 525 moléculas presentes também no arquivo do Kaggle, 99,6% têm o mesmo rótulo e 99,4% os mesmos descritores.

Tabela 1. Classes da base final. A última coluna é a proporção das 27.714 moléculas.

Alvo	ChEMBL ID	Moléculas	%
EGFR	CHEMBL203	8.108	29,3
BACE1	CHEMBL4822	7.344	26,5
DRD2	CHEMBL217	6.650	24,0
HDAC1	CHEMBL325	5.612	20,2

3.3. Problemas conhecidos

Há duas ressalvas. (i) Em 238 moléculas (0,86%) faltam LogP, HBA, HBD e TPSA, sobretudo em moléculas muito grandes; essas linhas foram removidas, restando 27.476 para modelagem. (ii) 4.777 linhas repetem exatamente os cinco descritores de outra linha, sempre da mesma classe; isso é a origem do vazamento tratado nas Seções 5.2 e 6.1.

O código, os notebooks e os dados estão em `https://github.com/pumba-dev/machine-learning-practice`. Os dados derivados do ChEMBL seguem a licença CC BY-SA 3.0.

4. Análise exploratória

As classes são razoavelmente balanceadas (Tabela 1): responder sempre EGFR, a majoritária, acerta 29,3%, e esse é o piso de comparação do restante do trabalho. A Figura 2 compara os cinco descritores entre os alvos. DRD2 tem TPSA e HBD claramente menores que os demais. EGFR tem os maiores valores de massa molecular, LogP e HBA. HDAC1 tem o maior HBD. BACE1 e HDAC1 se sobrepõem em massa molecular, TPSA e HBA.

TPSA, HBA e HBD são correlacionadas entre si (correlação de Spearman de 0,72 entre TPSA e HBA e de 0,69 entre TPSA e HBD). Isso não prejudica a árvore, mas divide a importância entre elas.

Para medir quanto cada descritor separa os alvos sozinho, fizemos um experimento: para cada um dos cinco, treinamos uma árvore de decisão de profundidade 3 que enxerga apenas aquele atributo e medimos sua acurácia por validação cruzada de 5 partes. Os resultados foram 37,8% (massa molecular), 38,7% (LogP), 43,3% (HBA), 44,9%

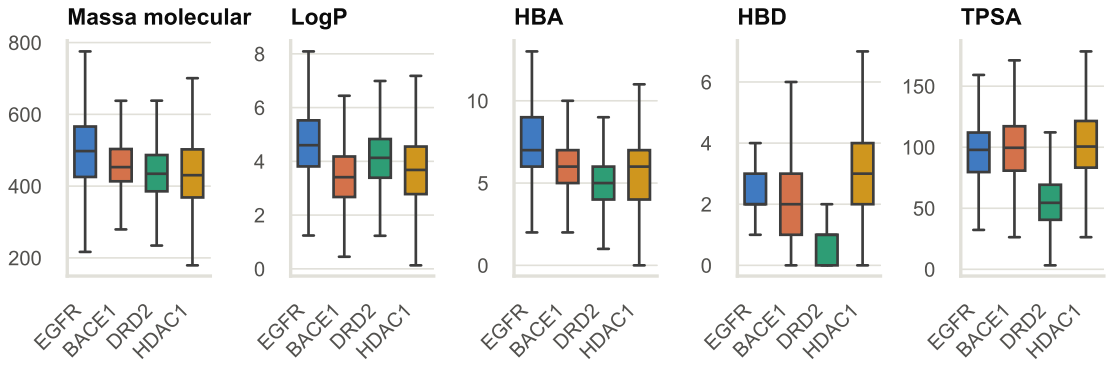


Figura 2. Descritores por proteína-alvo. Caixas mostram os quartis e as hastes 1,5 vez a amplitude interquartil; valores extremos foram omitidos.

(TPSA) e 45,1% (HBD). Todos superam os 29,3% de responder sempre a classe majoritária, mas nenhum passa de 45,1%. Nenhum descritor separa os alvos sozinho, então a árvore precisa combiná-los, e mesmo assim o desempenho esperado com só cinco descritores globais é limitado, sobretudo entre BACE1 e HDAC1. Isso motiva os atributos extraídos do SMILES (Seção 5).

5. Metodologia de modelagem

Tudo foi implementado em Python com scikit-learn [Pedregosa et al. 2011]. A tarefa é classificação multiclasse: prever a proteína-alvo (4 classes) das 27.476 moléculas com os cinco descritores completos.

5.1. Conjuntos de atributos

Além dos descritores, foram criados 12 atributos por contagem de caracteres do SMILES: comprimento da cadeia; número de átomos de N, O e S; de halogênios (F, Cl, Br, I); de anéis (dígitos de fechamento dividido por 2); de ramificações (`(`); de átomos aromáticos (c, n, o, s minúsculos); de ligações duplas (=) e triplas (`#`); de cargas (+, −); e de marcas de estereoquímica (`@`, `/`). Comparam-se três conjuntos de atributos: os 5 descritores, as 12 contagens de SMILES e os 17 atributos juntos.

5.2. Divisão treino-teste e vazamento

Os dados são divididos em treino (80%, 21.980 moléculas) e teste (20%, 5.496). Há um detalhe: moléculas diferentes podem ter exatamente os mesmos cinco valores de descritores (4.777 linhas repetem outra, sempre da mesma classe). Para o modelo, elas são o mesmo ponto. Se uma cai no treino e a outra no teste, acertar a segunda não exige generalizar: basta lembrar a primeira. Comparamos duas formas de dividir.

Na *divisão aleatória*, sorteia-se 20% das moléculas para o teste, mantendo a proporção de cada classe e sem olhar as repetições: moléculas com descritores idênticos podem ficar em lados opostos. Na *divisão agrupada*, primeiro reúnem-se num mesmo grupo todas as moléculas com os mesmos cinco descritores, e depois sorteiam-se grupos inteiros para o teste, também mantendo a proporção de classes: um grupo nunca é partido entre treino e teste. Na prática, usa-se uma validação cruzada de 5 partes, estratificada

por classe e sem separar grupos, e uma das partes (20%) serve de teste. A diferença de acurácia entre as duas divisões mede o vazamento [Kapoor and Narayanan 2023].

A combinação dos 3 conjuntos de atributos com as 2 divisões dá os 6 cenários da Tabela 2.

Tabela 2. Os seis cenários: cada conjunto de atributos com cada divisão treino-teste.

Cenário	Atributos	Divisão
C1	5 descritores	aleatória
C2	5 descritores	agrupada
C3	12 contagens de SMILES	aleatória
C4	12 contagens de SMILES	agrupada
C5	17 (descritores + contagens)	aleatória
C6	17 (descritores + contagens)	agrupada

5.3. Ajuste e avaliação da árvore de decisão

Em cada cenário da Tabela 2, uma busca em grade com validação cruzada de 5 partes escolhe os hiperparâmetros da árvore de decisão: critério de impureza (Gini ou entropia), profundidade máxima (8, 12, 16 ou sem limite), mínimo de amostras por folha (1, 5 ou 20) e parâmetro de poda por custo-complexidade α (0, 10^{-4} ou 3×10^{-4}), 72 combinações. A validação interna segue a mesma regra da divisão externa: na divisão agrupada, as partes também não separam grupos. A métrica de escolha é a acurácia. No teste, reportam-se acurácia, F1 macro (média simples do F1 das quatro classes), F1 por classe e a matriz de confusão. Como piso, usa-se um classificador que responde sempre a classe majoritária (EGFR).

5.4. Random Tree e conjuntos de árvores

Os demais modelos usam o mesmo treino, o mesmo teste e a mesma validação cruzada agrupada da árvore. A Random Tree é implementada como uma árvore do scikit-learn com sorteio de atributos em cada nó (`max_features`), o que reproduz o algoritmo do Weka. Ela é avaliada de duas formas nos seis cenários: com os padrões do Weka (entropia, $K = \lfloor \log_2 n \rfloor + 1$, sem poda, o que dá $K = 5$ com 17 atributos) e com uma busca em grade de 54 combinações (critério, fração de atributos sorteados de 0,25, 0,5 ou 0,75, profundidade máxima e mínimo por folha).

A Random Forest e o *gradient boosting* por histogramas são avaliados no cenário principal (17 atributos, divisão agrupada), com os padrões do scikit-learn e com uma busca leve: para a floresta, de 300 árvores, a fração de atributos sorteados e o mínimo por folha (6 combinações); para o *boosting*, com 300 iterações, a taxa de aprendizado e o número máximo de folhas por árvore (9 combinações). Dois recursos ficam desligados porque separam uma validação aleatória dentro do treino e deixariam gêmeas dos dois lados: a estimativa *out-of-bag* da floresta e a parada antecipada do *boosting*.

Para ver o efeito do sorteio de atributos numa árvore só e num conjunto, três modelos com a mesma árvore base, sem poda, são comparados na seed 42: a árvore de decisão (sem sorteio), a Random Tree com $K = \sqrt{n}$, o padrão da floresta, e a Random

Forest de 300 dessas árvores. As duas árvores únicas usam a média de 10 sementes, porque a Random Tree varia com a semente.

5.5. Repetição com várias seeds

Um único sorteio pode ser favorável ou desfavorável por acaso. Todo o procedimento acima, com todos os modelos, é repetido com 10 seeds (0 a 9), que mudam as duas divisões, as partes da validação cruzada e a semente dos modelos. As tabelas trazem média $\pm$ desvio padrão amostral. Ganhos e superestimativas são relativos, $(B - A)/A$, calculados em cada seed e depois resumidos pela média; a superestimativa compara a acurácia da divisão aleatória (B) com a da agrupada (A). As curvas, a árvore desenhada, a comparação entre as três árvores base e a análise de erros usam a seed 42. A variação das seeds cobre o sorteio da divisão, mas não a escolha dos dados: a base é a mesma em todas as repetições.

6. Resultados e discussão

Salvo indicação em contrário, os números são média $\pm$ desvio padrão em 10 seeds (Seção 5.5); as figuras e os exemplos de erro usam a seed 42. Acurácias e F1 estão em %; ganhos e superestimativas são relativos.

6.1. Vazamento por descritores repetidos

Das 27.476 moléculas, 22.699 têm uma tupla de descritores distinta e 4.777 repetem a de outra molécula (o maior grupo tem 12). Nenhum grupo mistura classes. Na divisão aleatória, 25,8 $\pm$ 0,4% das moléculas de teste têm uma gêmea de descritores no treino, isto é, outra molécula com exatamente os mesmos cinco valores. O efeito aparece na última coluna da Tabela 3: com só os cinco descritores, a divisão aleatória superestima a acurácia em 5,3 $\pm$ 1,2%, pois a árvore pode decorar as gêmeas. Com as contagens de SMILES o excesso cai para 1,5% tanto com elas sozinhas quanto com os 17 atributos, porque moléculas com os mesmos descritores têm SMILES diferentes e as contagens não são copiadas junto. A partir daqui, usa-se a divisão agrupada.

Tabela 3. Árvore de decisão no teste, por conjunto de atributos (média $\pm$ desvio em 10 seeds). Cada linha reúne dois cenários da Tabela 2. Superestimativa: quanto a acurácia da divisão aleatória excede a da agrupada, em termos relativos.

Atributos	Acurácia aleatória (%)	Acurácia agrupada (%)	F1 macro agrupado (%)	Superestimativa (%)
Descritores (5)	81,2 $\pm$ 0,5	77,1 $\pm$ 0,8	77,0 $\pm$ 0,8	5,3 $\pm$ 1,2
SMILES (12)	88,9 $\pm$ 0,4	87,6 $\pm$ 0,6	87,3 $\pm$ 0,6	1,5 $\pm$ 1,0
Ambos (17)	90,8 $\pm$ 0,3	89,4 $\pm$ 0,4	89,3 $\pm$ 0,4	1,5 $\pm$ 0,4

6.2. Efeito dos atributos de SMILES

Na divisão agrupada, os cinco descritores dão acurácia de 77,1 $\pm$ 0,8%. As 12 contagens de SMILES sozinhas chegam a 87,6 $\pm$ 0,6%, um ganho relativo de 14%. Os 17 atributos juntos chegam a 89,4 $\pm$ 0,4% (F1 macro de 89,3%), um ganho relativo de 16% sobre os descritores, muito acima da variação entre seeds. Contar letras de uma cadeia de texto

carrega mais informação sobre a molécula, como o número de anéis aromáticos e de halogênios, do que cinco propriedades globais. Na seed 42, a árvore escolhida acerta 89,7%, dentro da faixa de 88,6% a 89,9% observada nas 10 seeds.

6.3. Profundidade e poda

A busca em grade escolheu a entropia como critério e nenhum limite de profundidade nos seis cenários, e só ativou a poda quando os atributos eram apenas os descritores: com cerca de 22 mil linhas de treino, a regra de parada da própria árvore já fica perto do ideal. A Figura 3a mostra o motivo. A acurácia de treino chega a 100% na profundidade 25, enquanto a de validação estaciona em torno de 87% a partir da profundidade 16. A poda por custo-complexidade (Figura 3b) reduz a árvore de 2.054 para 899 folhas com $\alpha = 10^{-4}$ sem perder acurácia de validação (87,0% para 87,2%); acima de 10^{-3} a poda passa a custar acurácia, e com $\alpha = 10^{-2}$ sobram 8 folhas e 66,5%.

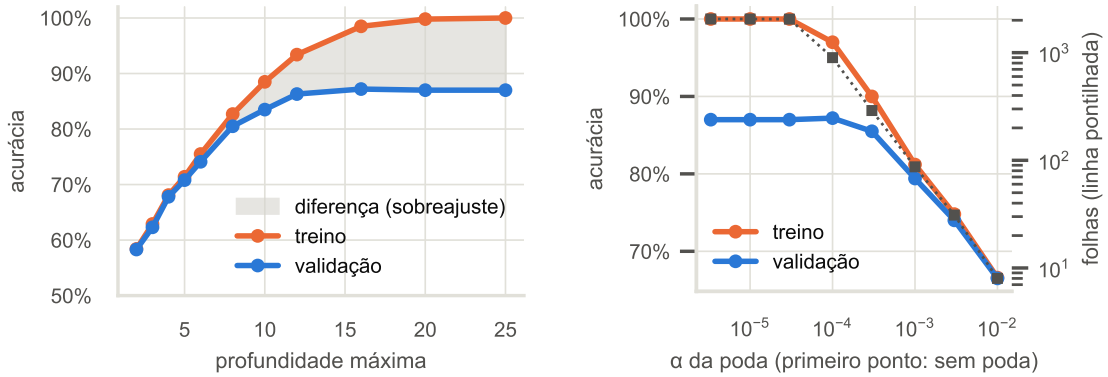


Figura 3. Acurácia de treino e de validação (seed 42, divisão agrupada, 17 atributos). (a) Por profundidade máxima. (b) Por α da poda, com o número de folhas na escala da direita (linha pontilhada); o primeiro ponto é $\alpha = 0$.

6.4. O que a árvore aprendeu

A árvore escolhida tem 1.854 folhas e 24 níveis, grande demais para ser desenhada. As primeiras camadas, porém, são legíveis (Figura 4). A raiz divide por TPSA (limiar de 67,9) e o ramo de TPSA baixa tem 69% de DRD2, como a análise exploratória antecipava. Em seguida vêm o número de átomos aromáticos, um atributo do SMILES, e depois HBD, número de anéis, comprimento do SMILES e número de halogênios. Descritores e contagens se misturam já no topo. A Figura 5 confirma o quadro: TPSA e o número de átomos aromáticos lideram nas duas medidas de importância, seguidos por HBD e por um bloco de contagens (átomos de N, halogênios, estereoquímica, anéis) acima de LogP e HBA. A importância por permutação, medida no teste, dá mais peso às contagens do que a de impureza.

6.5. Erros e limites da árvore

Entre as classes, BACE1 e DRD2 são as mais fáceis (F1 de 90,9% e 90,4%), seguidas de EGFR (89,2%) e HDAC1 (86,6%), a mais difícil. Na seed 42, o par HDAC1 $\leftrightarrow$ EGFR, nos dois sentidos, soma 28,7% dos 568 erros (Figura 6a), e 7,9% das moléculas de HDAC1 viram EGFR. Os erros não ocupam uma região do espaço de atributos: nenhum dos 17

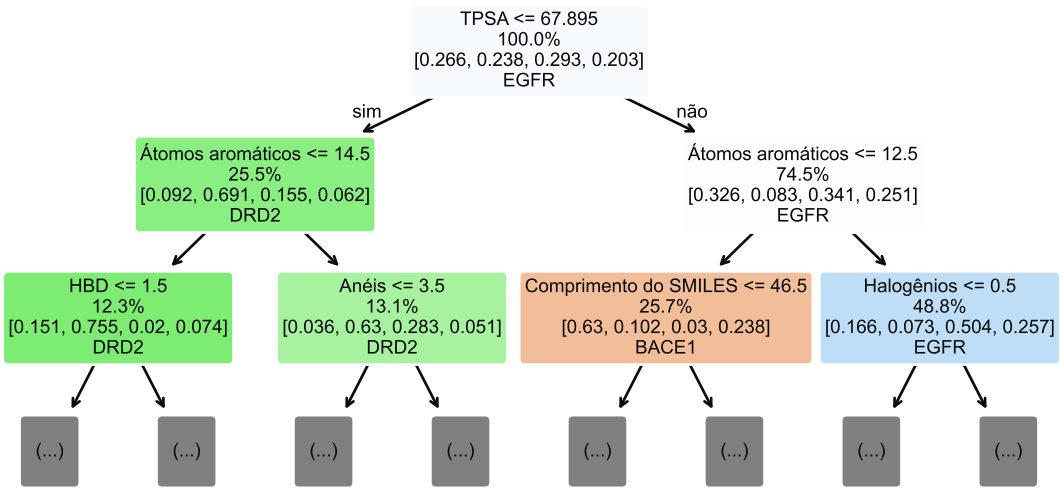


Figura 4. Três primeiras camadas da árvore escolhida (seed 42, divisão agrupada, 17 atributos). Cada nó mostra a regra de divisão, a fração das moléculas de treino que chega a ele, a proporção de cada classe (na ordem BACE1, DRD2, EGFR e HDAC1) e a classe majoritária, que também define a cor. A aresta "sim" leva às moléculas que satisfazem a regra; os nós cinza marcam subárvores omitidas.

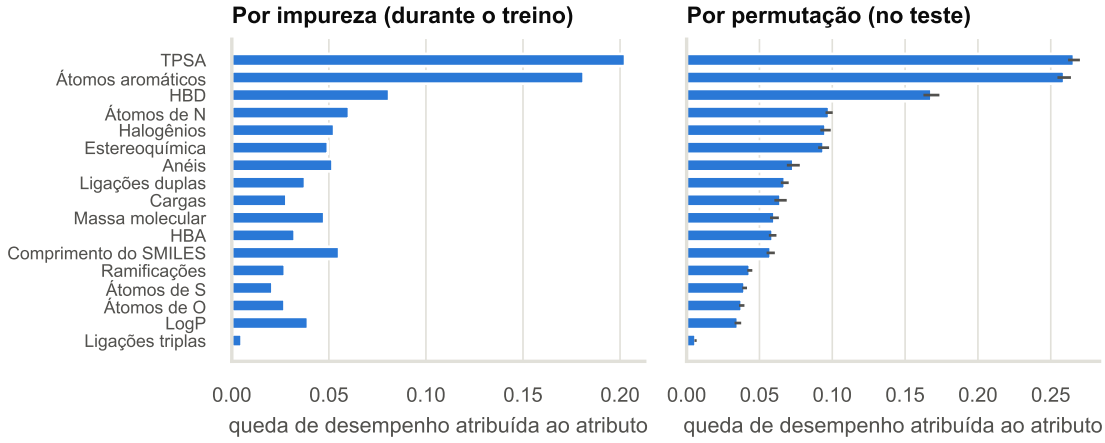


Figura 5. Importância dos atributos da árvore escolhida (seed 42). À esquerda, a redução de impureza acumulada nos nós que usam o atributo, durante o treino. À direita, a queda de acurácia no teste quando os valores do atributo são embaralhados (permutação).

atributos desloca a mediana entre acertos e erros em mais de meio intervalo interquartil. Entre seis exemplos de HDAC1 lidos como EGFR, dois contêm a mesma subestrutura, o grupo de átomos C(=O)NO. A árvore não a distingue: contagens de caracteres dizem quantos oxigênios e nitrogênios existem, mas não como estão ligados.

A árvore também não sabe quando erra. Sem poda, toda folha é pura, então a probabilidade de classe estimada pela árvore é 100% nas 5.496 previsões de teste, embora 10,3% estejam erradas. A curva de aprendizado (Figura 6b) mostra a outra limitação: o

treino fica em 100% e a validação sobe de 61,5% (879 linhas) para 87,0% (17.584) sem se achatar, de modo que mais moléculas provavelmente renderiam mais acurácia.

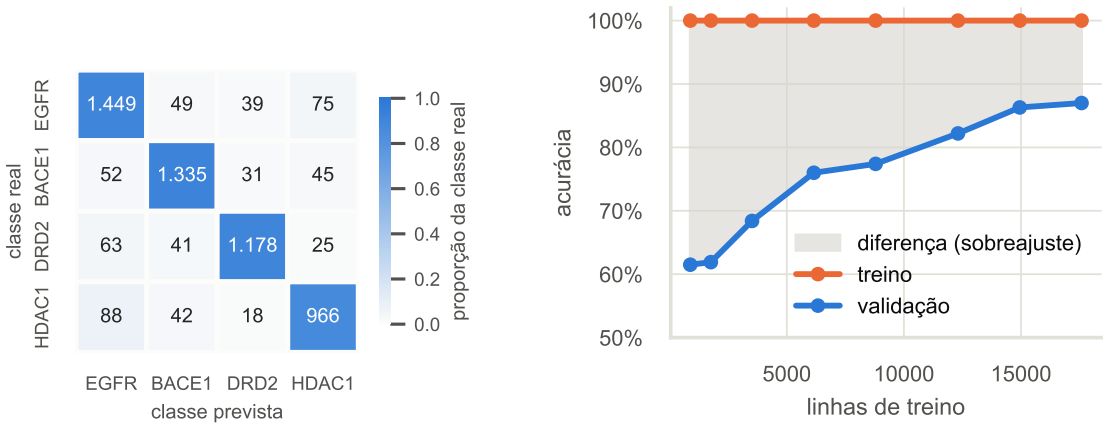


Figura 6. Seed 42, divisão agrupada, 17 atributos. (a) Matriz de confusão no teste: cor pela proporção da classe real, número em contagem. (b) Curva de aprendizado: acurácia por tamanho do conjunto de treino.

6.6. Random Tree

Sozinha, a Random Tree perde para a árvore de decisão. Com os padrões do Weka, ela acerta 87,6 $\pm$ 1,1% no cenário principal, 2,0% abaixo da árvore, e fica abaixo dela em todas as 10 seeds. Com a busca em grade, chega a 89,0 $\pm$ 0,7%, ainda 0,4% abaixo, e fica abaixo da árvore em 5 dos 6 cenários (Tabela 4). A maior perda, de 2,6%, ocorre com só os cinco descritores na divisão agrupada: com 5 atributos, sortear 3 em cada nó esconde quase metade das opções de corte. O único cenário sem perda, as contagens de SMILES na divisão aleatória, é um empate.

Tabela 4. Random Tree ajustada contra a árvore de decisão nos seis cenários (média $\pm$ desvio em 10 seeds). Diferença: relativa, calculada em cada seed. Última coluna: em quantas das 10 seeds a Random Tree acertou mais que a árvore.

Atributos	Divisão	Árvore de decisão (%)	Random Tree (%)	Diferença (%)	Seeds com RT melhor
Descritores (5)	Aleatória	81,2 $\pm$ 0,5	80,5 $\pm$ 0,6	−0,9	1
Descritores (5)	Agrupada	77,1 $\pm$ 0,8	75,1 $\pm$ 1,0	−2,6	0
SMILES (12)	Aleatória	88,9 $\pm$ 0,4	88,9 $\pm$ 0,6	0,0	6
SMILES (12)	Agrupada	87,6 $\pm$ 0,6	87,4 $\pm$ 0,7	−0,2	4
Ambos (17)	Aleatória	90,8 $\pm$ 0,3	90,5 $\pm$ 0,5	−0,3	2
Ambos (17)	Agrupada	89,4 $\pm$ 0,4	89,0 $\pm$ 0,7	−0,4	3

A busca em grade puxa a Random Tree de volta na direção da árvore de decisão: em 5 dos 6 cenários ela escolhe sortear 75% dos atributos, a maior fração do grid. A Figura 7 mostra o mesmo efeito na seed 42. A acurácia de validação sobe de 78,7% com $K = 1$ para 86,7% com $K = 5$, o padrão do Weka, e depois fica num platô de 86,6% a 88,1%. Com $K = 17$ não há sorteio, e o modelo é a própria árvore de decisão. O sorteio também deixa o resultado instável: só trocando a semente, com os mesmos dados

e a mesma divisão, a acurácia de teste da Random Tree ajustada vai de 87,8% a 89,8% em 50 sementes (desvio de 0,45 ponto), contra 88,7% a 89,4% da árvore com os mesmos hiperparâmetros (desvio de 0,17). A Random Tree aprende o mesmo que a árvore: TPSA e o número de átomos aromáticos lideram a importância, HDAC1 é a classe mais difícil e o par HDAC1 $\leftrightarrow$ EGFR concentra os erros.

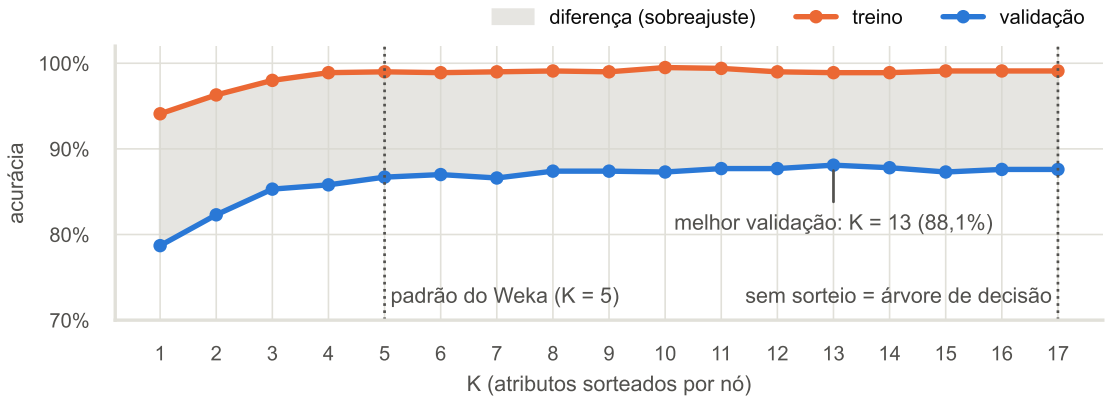


Figura 7. Random Tree: acurácia de treino e de validação agrupada por número K de atributos sorteados em cada nó (seed 42, 17 atributos, demais hiperparâmetros escolhidos pela busca). $K = 17$ desliga o sorteio e equivale à árvore de decisão.

6.7. Árvore única contra conjuntos de árvores

A Tabela 5 reúne todos os modelos no cenário principal. Eles formam dois grupos, separados por uma distância muito maior que o desvio entre seeds: as árvores únicas, de 87,6% a 89,4%, e a Random Forest e o *gradient boosting*, de 94,8% a 96,6%. Todos os conjuntos superam a árvore nas 10 seeds. O *gradient boosting* ajustado é o mais preciso, com 96,6 $\pm$ 0,3%, 8,1% acima da árvore.

Tabela 5. Todos os modelos na divisão agrupada, com os 17 atributos (média $\pm$ desvio em 10 seeds). Diferença para a árvore: relativa, calculada em cada seed.

Modelo	Acurácia (%)	F1 macro (%)	Diferença para a árvore (%)
Classe majoritária (EGFR)	29,3 $\pm$ 0,0	11,3 $\pm$ 0,0	–
Árvore de decisão	89,4 $\pm$ 0,4	89,3 $\pm$ 0,4	–
Random Tree (padrão do Weka)	87,6 $\pm$ 1,1	87,5 $\pm$ 1,1	$-$2,0
Random Tree (ajustada)	89,0 $\pm$ 0,7	88,9 $\pm$ 0,7	$-$0,4
Random Forest (padrão)	95,2 $\pm$ 0,3	95,1 $\pm$ 0,3	6,4
Random Forest (ajustada)	95,3 $\pm$ 0,3	95,2 $\pm$ 0,3	6,5
Gradient boosting (padrão)	94,8 $\pm$ 0,3	94,7 $\pm$ 0,3	6,0
Gradient boosting (ajustado)	96,6 $\pm$ 0,3	96,6 $\pm$ 0,2	8,1

O ajuste de hiperparâmetros pesa de forma diferente nos dois conjuntos. Na Random Forest, a floresta ajustada (95,3%) empata com a padrão (95,2%): as melhores combinações da busca ficam dentro de 0,4 ponto de validação, e só o mínimo de uma amostra por folha importa. No *boosting*, o ajuste rende 7,2 pontos sobre a árvore, contra 5,4 do

padrão. Boa parte da diferença vem do que mudou junto com o grid: o padrão do scikit-learn usa 100 iterações e, com mais de 10 mil linhas, para cedo com base numa validação aleatória de 10% do treino, que aqui contém gêmeas. Com 300 iterações e sem parada antecipada, a acurácia de treino chega a 100% em 50 iterações e a de validação continua a subir até cerca de 200.

A Figura 8a (seed 42) mostra o efeito do sorteio de atributos numa árvore só e num conjunto, com a mesma árvore base. A árvore de decisão sem poda acerta 88,5%. Com sorteio ($K = \sqrt{17}$), a árvore única cai para 86,6% ($-1{,}9$ ponto), e o desvio entre sementes fica cinco vezes maior (0,87 contra 0,16 ponto): uma árvore única quer o melhor corte de cada nó, e o sorteio às vezes o esconde. Já 300 dessas árvores, cada uma numa amostra *bootstrap* do treino, formam a Random Forest, que acerta 95,2%, 6,7 pontos acima da árvore de decisão. No conjunto, o sorteio é o que torna as árvores diferentes entre si: elas erram em moléculas diferentes, e a média cancela os erros. A Figura 8b mostra o ganho crescendo com o número de árvores: com uma ou duas, a floresta fica perto de 84%, abaixo da árvore de decisão, porque cada árvore vê só uma amostra do treino e um sorteio dos atributos; com cinco, já passa de 91%, e a partir de 50 árvores fica estável, perto de 94%. É por isso que a Random Tree perde sozinha e, ainda assim, é a peça da Random Forest.

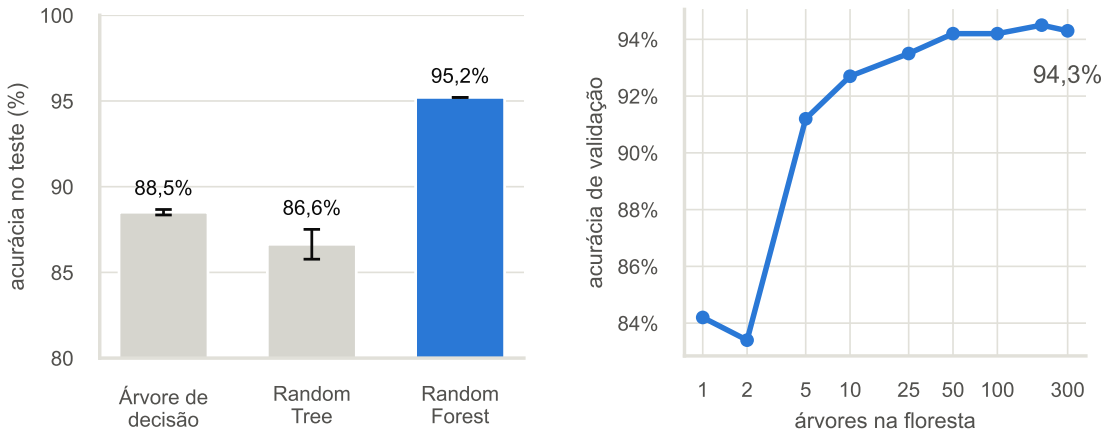


Figura 8. Da árvore à Random Forest (seed 42, divisão agrupada, 17 atributos). (a) Acurácia no teste da árvore de decisão sem poda, da Random Tree ($K = \sqrt{17}$) e da Random Forest de 300 dessas árvores; as árvores únicas mostram a média e o desvio de 10 sementes; o eixo começa em 80%. (b) Acurácia de validação agrupada da Random Forest por número de árvores.

Os conjuntos melhoram todas as classes, e HDAC1 é a que mais ganha: o F1 sobe de 86,6% na árvore para 95,4% no *boosting* ajustado. A confusão de fundo, porém, continua: o par HDAC1 $\leftrightarrow$ EGFR soma cerca de 30% dos erros em todos os modelos, que caem de 568 na árvore para 279 na Random Forest e 191 no *boosting* (seed 42). Nenhum modelo enxerga a subestrutura que as contagens não representam.

A confiança dos modelos também difere. A árvore e a Random Tree dizem 100% em quase tudo. A Random Forest sabe quando está em dúvida: as previsões com confiança abaixo de 70% são 19,8% do teste, mas reúnem 91% dos erros, e acima de 90% de confiança ela não erra. O *boosting* é confiante demais: 89,2% das previsões saem com

mais de 99,9% de confiança, e essa faixa ainda guarda 20% dos erros. Para separar as previsões que merecem revisão, a Random Forest é a mais útil, apesar de acertar 1,5 ponto a menos que o *boosting*. Em todos os casos, o ganho de acurácia custa a legibilidade: só a árvore de decisão responde, com um caminho de perguntas, por que uma molécula foi classificada como DRD2.

7. Limitações

O agrupamento por descritores idênticos não cobre famílias de moléculas muito parecidas entre si, que continuam espalhadas entre treino e teste; as contagens de SMILES permitem decorar essas famílias. Dividir por família (esqueleto molecular) controlaria isso, mas exige uma biblioteca de química. Por isso a acurácia de 89,4% ainda é otimista para moléculas realmente novas.

O modelo escolhe sempre uma entre quatro classes: não existe a opção "nenhuma das quatro", então ele não sabe dizer que uma molécula não pertence a nenhum dos alvos. As 10 seeds variam o sorteio da divisão, mas os dados são os mesmos, de modo que o desvio padrão não mede a incerteza para dados novos, e não há validação externa. Por fim, as 238 moléculas sem descritores (0,86%) foram descartadas, em sua maioria muito grandes, e as probabilidades da árvore não são calibradas.

Na comparação entre modelos, a busca da Random Forest e do *gradient boosting* foi leve e feita só no cenário principal, de modo que o teto pode estar um pouco subestimado. A comparação entre as três árvores base e as curvas usam uma única seed. A Random Tree foi reproduzida no scikit-learn a partir da descrição do algoritmo do Weka, sem rodar o próprio Weka, e pode diferir dele em detalhes como o tratamento de empates. Os tempos de treino não são reportados porque foram medidos com a máquina ocupada por outros processos.

8. Conclusão e trabalhos futuros

Reconstruímos do ChEMBL_37 uma base de 27.714 moléculas, cada uma associada a um de quatro alvos (EGFR, BACE1, DRD2 e HDAC1), e treinamos uma árvore de decisão para prever o alvo. Com divisão agrupada, os cinco descritores físico-químicos dão acurácia de 77,1%; acrescentar 12 contagens de caracteres do SMILES leva a 89,4 $\pm$ 0,4% (ganho relativo de 16%), e as contagens sozinhas já chegam a 87,6%. A divisão aleatória superestima o resultado em 1,5% a 5,3% (relativo) porque cerca de um quarto das moléculas de teste tem gêmea de descritores no treino. TPSA e o número de átomos aromáticos são os atributos mais importantes, e o par HDAC1–EGFR concentra 28,7% dos erros.

Na comparação com a Random Tree e com conjuntos de árvores, a árvore de decisão segue como a melhor árvore única. A Random Tree fica 0,4% abaixo dela quando ajustada e 2,0% abaixo com os padrões do Weka, e varia mais com a semente: o sorteio de atributos esconde o melhor corte de cada nó, e uma árvore só não tem como compensar. Nos conjuntos, o mesmo sorteio ajuda: torna as árvores diferentes entre si, e 300 Random Trees juntas, a Random Forest, acertam 6,7 pontos a mais que a árvore de decisão na seed 42. O *gradient boosting* ajustado é o modelo mais preciso (96,6%, 8,1% acima da árvore). A Random Forest chega a 95,2% sem ajuste e é a única cuja confiança separa acertos de erros. Em troca, só a árvore de decisão oferece regras legíveis.

Quatro caminhos seguem do que foi visto. Representações estruturais da molécula (*fingerprints*), calculadas com uma biblioteca de química, enxergariam subestruturas como o grupo C(=O)NO, que as contagens não veem. Uma divisão por esqueleto molecular daria uma estimativa menos otimista para moléculas novas. A curva de aprendizado ainda sobe, o que sugere buscar mais dados no ChEMBL, com outros alvos ou um limiar de pChEMBL mais baixo. Por fim, calibrar as probabilidades do *gradient boosting*, hoje confiante demais, permitiria usar a confiança do modelo mais preciso para escolher quais previsões revisar.

Referências

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth International Group, Belmont, CA.

Davies, M., Nowotka, M., Papadatos, G., Dedman, N., Gaulton, A., Atkinson, F., Bellis, L., and Overington, J. P. (2015). ChEMBL web services: streamlining access to drug discovery data and utilities. *Nucleic Acids Research*, 43(W1):W612–W620.

Ertl, P., Rohde, B., and Selzer, P. (2000). Fast calculation of molecular polar surface area as a sum of fragment-based contributions and its application to the prediction of drug transport properties. *Journal of Medicinal Chemistry*, 43:3714–3717.

Friedman, J. H. (2001). Greedy function approximation: a gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232.

Gaulton, A. et al. (2012). ChEMBL: a large-scale bioactivity database for drug discovery. *Nucleic Acids Research*, 40(D1):D1100–D1107.

Kapoor, S. and Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. (2017). LightGBM: a highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30*, pages 3146–3154.

Keiser, M. J., Roth, B. L., Armbruster, B. N., Ernsberger, P., Irwin, J. J., and Shoichet, B. K. (2007). Relating protein pharmacology by ligand chemistry. *Nature Biotechnology*, 25(2):197–206.

Lipinski, C. A., Lombardo, F., Dominy, B. W., and Feeney, P. J. (2001). Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. *Advanced Drug Delivery Reviews*, 46(1–3):3–26.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Sheridan, R. P. (2013). Time-split cross-validation as a method for estimating the goodness of prospective prediction. *Journal of Chemical Information and Modeling*, 53(4):783–790.

Weininger, D. (1988). SMILES, a chemical language and information system. 1. introduction to methodology and encoding rules. *Journal of Chemical Information and Computer Sciences*, 28(1):31–36.

Witten, I. H., Frank, E., Hall, M. A., and Pal, C. J. (2016). *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann, 4 edition.

xjoannax88 (2026). MultiTarget Bioactivity ChEMBL. Kaggle, versão 17. `https://www.kaggle.com/datasets/xjoannax88/multitarget-bioactivity-chembl`.

Zdrazil, B. et al. (2024). The ChEMBL database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods. *Nucleic Acids Research*, 52(D1):D1180–D1192.