Classificação de alvos proteicos a partir de descritores moleculares do ChEMBL com árvores de decisão

Bernan R. do Nascimento[1], **Paulo E. R. Araujo**[1], **Thiago R. P. de Carvalho**[1]

[1]Universidade Federal do Piauí (UFPI)
Programa de Pós-Graduação em Ciência da Computação – Teresina – PI – Brasil
PPGCC010 – Aprendizagem de Máquina (2026.2) – Prof. Vinicius Ponte Machado

bernanr7@gmail.com, pauloaraujo@ufpi.edu.br

thiago.rafael.pc@gmail.com

Abstract. *Predicting which protein target a molecule is associated with is an early step in drug discovery. We rebuild from the ChEMBL 37 API a dataset of 27,714 molecules, each associated with one of four targets (EGFR, BACE1, DRD2 and HDAC1), and train a decision tree on five physicochemical descriptors and twelve counts taken from the SMILES string, a text that describes a molecule's structure. With a grouped split, the SMILES counts raise accuracy from 77.1% to 89.4% (a 16% relative gain; mean of 10 seeds). A random split overestimates accuracy by up to 5.3%, because a quarter of the test molecules have a twin with identical descriptors in the training set; the grouped split keeps such twins on the same side.*

Resumo. *Prever a qual proteína-alvo uma molécula está associada é uma etapa inicial da descoberta de fármacos. Reconstruímos pela API do ChEMBL 37 uma base de 27.714 moléculas, cada uma associada a um de quatro alvos (EGFR, BACE1, DRD2 e HDAC1), e treinamos uma árvore de decisão com cinco descritores físico-químicos e doze contagens extraídas do SMILES, texto que descreve a estrutura da molécula. Com divisão agrupada, as contagens elevam a acurácia de 77,1% para 89,4% (ganho relativo de 16%; média de 10 seeds). A divisão aleatória superestima o resultado em até 5,3%, pois um quarto das moléculas de teste tem uma gêmea de descritores idênticos no treino; a divisão agrupada mantém essas gêmeas do mesmo lado.*

1. Introdução

Na descoberta de fármacos, saber a qual proteína uma molécula está associada ajuda a priorizar experimentos. Bancos abertos como o ChEMBL [Gaulton et al. 2012, Zdrazil et al. 2024] reúnem milhões de medições de potência de moléculas contra proteínas, e com eles é possível treinar modelos que sugerem o alvo de uma molécula [Keiser et al. 2007].

Este trabalho trata uma versão controlada do problema: dada uma molécula associada a exatamente uma de quatro proteínas (EGFR, BACE1, DRD2 e HDAC1), prever qual é. A molécula é descrita por números calculados a partir dela: cinco descritores físico-químicos e contagens extraídas do SMILES, um texto que descreve a estrutura da molécula. O modelo é uma árvore de decisão [Breiman et al. 1984], escolhida porque suas regras podem ser lidas e discutidas.

Três pontos tornam o problema menos trivial do que parece. Primeiro, o conjunto do Kaggle que inspirou o trabalho está incompleto e foi preciso reconstruí-lo do ChEMBL. Segundo, cinco descritores globais separam mal as classes. Terceiro, muitas moléculas compartilham exatamente os mesmos descritores: se uma cai no treino e outra no teste, o modelo é premiado por memorizar. Por isso comparamos a divisão aleatória, que sorteia as moléculas livremente, com a divisão agrupada, que mantém do mesmo lado as moléculas de descritores idênticos (Seção 5.2). As contribuições são:

- uma base reconstruída do ChEMBL_37, com 27.714 moléculas de quatro alvos e curadoria documentada passo a passo;
- 12 atributos obtidos apenas contando caracteres do SMILES, que, somados aos descritores, elevam a acurácia da árvore em 16% (ganho relativo);
- uma avaliação com divisão agrupada e 10 seeds, que mede o quanto a divisão aleatória superestima o resultado (de 1,5% a 5,3%, em termos relativos) e situa a árvore entre um piso e um teto dados por modelos de referência.

2. Fundamentação e trabalhos relacionados

Predição de alvos. Bancos como o ChEMBL [Gaulton et al. 2012, Zdrazil et al. 2024] reúnem medições de potência de moléculas contra alvos proteicos. Uma abordagem clássica para sugerir o alvo de uma molécula compara conjuntos de moléculas por similaridade química e relaciona proteínas pela semelhança do que elas ligam, o que permitiu prever interações novas depois confirmadas em laboratório [Keiser et al. 2007]. Este trabalho segue outra linha, mais simples e interpretável: classificar a molécula a partir de atributos numéricos calculados dela.

Descritores e SMILES. A regra dos cinco de Lipinski [Lipinski et al. 2001] usa massa molecular, LogP e os números de doadores e aceptores de ligação de hidrogênio, propriedades calculadas direto da estrutura da molécula. A TPSA [Ertl et al. 2000] é a área polar da molécula, estimada somando contribuições de fragmentos. O SMILES [Weininger 1988] descreve a molécula como texto: letras são átomos, dígitos fecham anéis e parênteses abrem ramificações. Contar esses símbolos dá atributos de composição sem analisar a estrutura, ao custo de não enxergar subestruturas, isto é, como os átomos estão ligados entre si.

Árvores de decisão. O CART [Breiman et al. 1984] divide o espaço de atributos de forma recursiva, em cada nó escolhendo o limiar de um atributo que mais reduz a impureza (Gini ou entropia). Sem limite de profundidade, a árvore acerta todo o treino; a poda por custo-complexidade, controlada por α, corta ramos que pouco reduzem o erro e diminui o número de folhas. A vantagem é a legibilidade das regras. Como referência de desempenho usam-se conjuntos de árvores, como a Random Forest [Breiman 2001], mais precisos e menos interpretáveis.

Vazamento e validação. Vazamento de dados, quando informação do teste chega ao treino, é uma causa documentada de resultados superestimados em ciência baseada em aprendizado de máquina [Kapoor and Narayanan 2023]. Em química, a divisão aleatória já é conhecida por ser otimista; Sheridan [Sheridan 2013] mostra que separar treino e teste por data estima melhor o desempenho prospectivo. Aqui o vazamento é mais direto: moléculas distintas com os mesmos cinco descritores podem cair em lados opostos da divisão. Por isso o teste agrupa as moléculas pela tupla de descritores (Seção 5.2).

3. Dados e curadoria

3.1. Base de partida

O trabalho partiu do conjunto *MultiTarget Bioactivity ChEMBL*, publicado no Kaggle [xjoannax88 2026]. O arquivo disponível, porém, não corresponde à descrição da própria página: tem 1.333 linhas em vez de 8.711, nenhuma molécula de EGFR, apenas duas de BACE1 e 95,5% das linhas em DRD2. A página também associa BACE1 ao identificador CHEMBL1987, que designa outra proteína; o correto é CHEMBL4822. Como as versões anteriores exigem login para download, a base foi reconstruída diretamente do ChEMBL.

3.2. Reconstrução a partir do ChEMBL

Os dados vêm da API REST do ChEMBL [Davies et al. 2015], um banco curado de moléculas e de suas medições de potência [Gaulton et al. 2012, Zdrazil et al. 2024], na versão ChEMBL_37 (lançada em 01/05/2026, extração em 24/10/2026). Para cada um dos quatro alvos da Tabela 1 foram baixadas as medições de ensaios de ligação com valor exato (sem desigualdades) e com pChEMBL preenchido. O pChEMBL é uma medida de potência padronizada pelo ChEMBL ($-\log_{10}$ de uma concentração molar): quanto maior, mais potente a molécula contra o alvo. Neste trabalho, uma molécula é associada a um alvo quando seu pChEMBL contra ele é de pelo menos 6, o que equivale a 1 μM.

A Figura 1 resume a curadoria. As 58.736 medições brutas perdem 7.328 registros marcados pelo ChEMBL como duplicata potencial e 49 sem SMILES. As 51.359 restantes são agregadas pela mediana do pChEMBL em cada par molécula-alvo (37.424 pares). Mantêm-se os pares com pChEMBL ≥ 6 (27.798) e removem-se 42 moléculas associadas a mais de um alvo, cujo rótulo seria ambíguo. O resultado são 27.714 moléculas, uma por linha, com a proteína-alvo como classe.

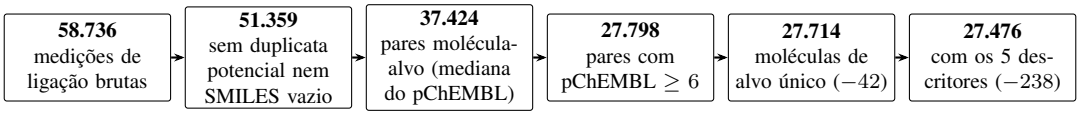


Figura 1. Funil de curadoria, do download à base de modelagem.

Cada molécula é descrita pelos cinco descritores que o ChEMBL calcula para ela: massa molecular, LogP, números de aceptores e doadores de ligação de hidrogênio (HBA e HBD) e área de superfície polar topológica (TPSA) [Ertl et al. 2000]. O pChEMBL não é usado como atributo, pois resulta do ensaio contra o próprio alvo e vazaria o rótulo. Nas 525 moléculas presentes também no arquivo do Kaggle, 99,6% têm o mesmo rótulo e 99,4% os mesmos descritores.

3.3. Problemas conhecidos

Há duas ressalvas. (i) Em 238 moléculas (0,86%) faltam LogP, HBA, HBD e TPSA, sobretudo em moléculas muito grandes; essas linhas foram removidas, restando 27.476 para modelagem. (ii) 4.777 linhas repetem exatamente os cinco descritores de outra linha, sempre da mesma classe; isso é a origem do vazamento tratado nas Seções 5.2 e 6.1.

O código, os notebooks e os dados estão em `https://github.com/pumba-dev/machine-learning-practice`. Os dados derivados do ChEMBL seguem a licença CC BY-SA 3.0.

Tabela 1. Classes da base final. A última coluna é a proporção das 27.714 moléculas.

Alvo	ChEMBL ID	Moléculas	%
EGFR	CHEMBL203	8.108	29,3
BACE1	CHEMBL4822	7.344	26,5
DRD2	CHEMBL217	6.650	24,0
HDAC1	CHEMBL325	5.612	20,2

4. Análise exploratória

As classes são razoavelmente balanceadas (Tabela 1): responder sempre EGFR, a majoritária, acerta 29,3%, e esse é o piso de comparação do restante do trabalho. A Figura 2 compara os cinco descritores entre os alvos. DRD2 tem TPSA e HBD claramente menores que os demais. EGFR tem os maiores valores de massa molecular, LogP e HBA. HDAC1 tem o maior HBD. BACE1 e HDAC1 se sobrepõem em massa molecular, TPSA e HBA.

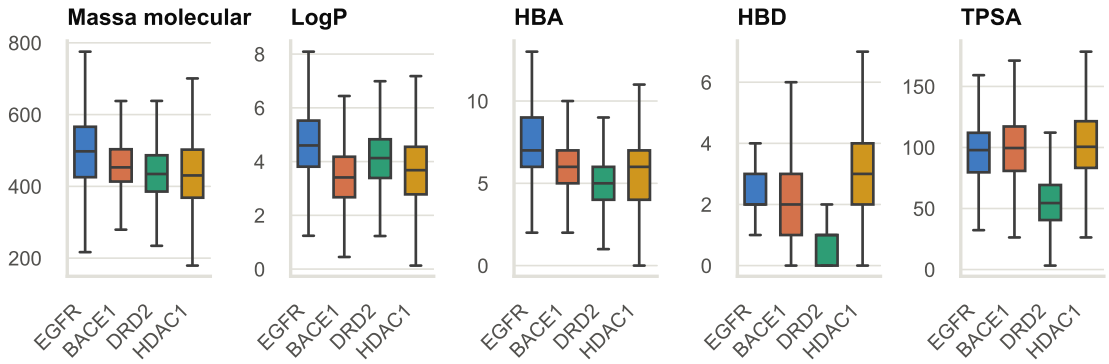


Figura 2. Descritores por proteína-alvo. Caixas mostram os quartis e as hastes 1,5 vez a amplitude interquartil; valores extremos foram omitidos.

TPSA, HBA e HBD são correlacionadas entre si (correlação de Spearman de 0,72 entre TPSA e HBA e de 0,69 entre TPSA e HBD). Isso não prejudica a árvore, mas divide a importância entre elas.

Para medir quanto cada descritor separa os alvos sozinho, fizemos um experimento: para cada um dos cinco, treinamos uma árvore de decisão de profundidade 3 que enxerga apenas aquele atributo e medimos sua acurácia por validação cruzada de 5 partes. Os resultados foram 37,8% (massa molecular), 38,7% (LogP), 43,3% (HBA), 44,9% (TPSA) e 45,1% (HBD). Todos superam os 29,3% de responder sempre a classe majoritária, mas nenhum passa de 45,1%. Nenhum descritor separa os alvos sozinho, então a árvore precisa combiná-los, e mesmo assim o desempenho esperado com só cinco descritores globais é limitado, sobretudo entre BACE1 e HDAC1. Isso motiva os atributos extraídos do SMILES (Seção 5).

5. Metodologia de modelagem

Tudo foi implementado em Python com scikit-learn [Pedregosa et al. 2011]. A tarefa é classificação multiclasse: prever a proteína-alvo (4 classes) das 27.476 moléculas com os

cinco descritores completos.

5.1. Conjuntos de atributos

Além dos descritores, foram criados 12 atributos por contagem de caracteres do SMILES: comprimento da cadeia; número de átomos de N, O e S; de halogênios (F, Cl, Br, I); de anéis (dígitos de fechamento dividido por 2); de ramificações (`(`); de átomos aromáticos (c, n, o, s minúsculos); de ligações duplas (=) e triplas (#); de cargas (+, −); e de marcas de estereoquímica (`@`, `/`). Comparam-se três conjuntos de atributos: os 5 descritores, as 12 contagens de SMILES e os 17 atributos juntos.

5.2. Divisão treino-teste e vazamento

Os dados são divididos em treino (80%, 21.980 moléculas) e teste (20%, 5.496). Há um detalhe: moléculas diferentes podem ter exatamente os mesmos cinco valores de descritores (4.777 linhas repetem outra, sempre da mesma classe). Para o modelo, elas são o mesmo ponto. Se uma cai no treino e a outra no teste, acertar a segunda não exige generalizar: basta lembrar a primeira. Comparamos duas formas de dividir.

Na *divisão aleatória*, sorteia-se 20% das moléculas para o teste, mantendo a proporção de cada classe e sem olhar as repetições: moléculas com descritores idênticos podem ficar em lados opostos. Na *divisão agrupada*, primeiro reúnem-se num mesmo grupo todas as moléculas com os mesmos cinco descritores, e depois sorteiam-se grupos inteiros para o teste, também mantendo a proporção de classes: um grupo nunca é partido entre treino e teste. Na prática, usa-se uma validação cruzada de 5 partes, estratificada por classe e sem separar grupos, e uma das partes (20%) serve de teste. A diferença de acurácia entre as duas divisões mede o vazamento [Kapoor and Narayanan 2023].

A combinação dos 3 conjuntos de atributos com as 2 divisões dá os 6 cenários da Tabela 2.

Tabela 2. Os seis cenários: cada conjunto de atributos com cada divisão treino-teste.

Cenário	Atributos	Divisão
C1	5 descritores	aleatória
C2	5 descritores	agrupada
C3	12 contagens de SMILES	aleatória
C4	12 contagens de SMILES	agrupada
C5	17 (descritores + contagens)	aleatória
C6	17 (descritores + contagens)	agrupada

5.3. Ajuste, avaliação e modelos de referência

Em cada cenário da Tabela 2, uma busca em grade com validação cruzada de 5 partes escolhe os hiperparâmetros da árvore de decisão: critério de impureza (Gini ou entropia), profundidade máxima (8, 12, 16 ou sem limite), mínimo de amostras por folha (1, 5 ou 20) e parâmetro de poda por custo-complexidade α (0, 10^{-4} ou 3×10^{-4}), 72 combinações. A validação interna segue a mesma regra da divisão externa: na divisão agrupada, as partes também não separam grupos. A métrica de escolha é a acurácia. No teste, reportam-se

acurácia, F1 macro (média simples do F1 das quatro classes), F1 por classe e a matriz de confusão.

Como piso e teto, usam-se no mesmo treino e teste um classificador que responde sempre a classe majoritária (EGFR), uma Random Forest [Breiman 2001] de 300 árvores e um *gradient boosting* baseado em histogramas, ambos sem ajuste de hiperparâmetros.

5.4. Repetição com várias seeds

Um único sorteio pode ser favorável ou desfavorável por acaso. Todo o procedimento acima é repetido com 10 seeds (0 a 9), que mudam as duas divisões, as partes da validação cruzada e a semente dos modelos. As tabelas trazem média $\pm$ desvio padrão amostral. Ganhos e superestimativas são relativos, $(B - A)/A$, calculados em cada seed e depois resumidos pela média; a superestimativa compara a acurácia da divisão aleatória (B) com a da agrupada (A). As curvas, a árvore desenhada e a análise de erros usam a seed 42. A variação das seeds cobre o sorteio da divisão, mas não a escolha dos dados: a base é a mesma em todas as repetições.

6. Resultados e discussão

Salvo indicação em contrário, os números são média $\pm$ desvio padrão em 10 seeds (Seção 5.4); as figuras e os exemplos de erro usam a seed 42. Acurácias e F1 estão em %; ganhos e superestimativas são relativos.

6.1. Vazamento por descritores repetidos

Das 27.476 moléculas, 22.699 têm uma tupla de descritores distinta e 4.777 repetem a de outra molécula (o maior grupo tem 12). Nenhum grupo mistura classes. Na divisão aleatória, 25,8 $\pm$ 0,4% das moléculas de teste têm uma gêmea de descritores no treino, isto é, outra molécula com exatamente os mesmos cinco valores. O efeito aparece na última coluna da Tabela 3: com só os cinco descritores, a divisão aleatória superestima a acurácia em 5,3 $\pm$ 1,2%, pois a árvore pode decorar as gêmeas. Com as contagens de SMILES o excesso cai para 1,5% tanto com elas sozinhas quanto com os 17 atributos, porque moléculas com os mesmos descritores têm SMILES diferentes e as contagens não são copiadas junto. A partir daqui, usa-se a divisão agrupada.

Tabela 3. Árvore de decisão no teste, por conjunto de atributos (média $\pm$ desvio em 10 seeds). Cada linha reúne dois cenários da Tabela 2. Superestimativa: quanto a acurácia da divisão aleatória excede a da agrupada, em termos relativos.

Atributos	Acurácia aleatória (%)	Acurácia agrupada (%)	F1 macro agrupado (%)	Superestimativa (%)
Descritores (5)	81,2 $\pm$ 0,5	77,1 $\pm$ 0,8	77,0 $\pm$ 0,8	5,3 $\pm$ 1,2
SMILES (12)	88,9 $\pm$ 0,4	87,6 $\pm$ 0,6	87,3 $\pm$ 0,6	1,5 $\pm$ 1,0
Ambos (17)	90,8 $\pm$ 0,3	89,4 $\pm$ 0,4	89,3 $\pm$ 0,4	1,5 $\pm$ 0,4

6.2. Efeito dos atributos de SMILES

Na divisão agrupada, os cinco descritores dão acurácia de 77,1 $\pm$ 0,8%. As 12 contagens de SMILES sozinhas chegam a 87,6 $\pm$ 0,6%, um ganho relativo de 14%. Os 17 atributos

juntos chegam a 89,4 $\pm$ 0,4% (F1 macro de 89,3%), um ganho relativo de 16% sobre os descritores, muito acima da variação entre seeds. Contar letras de uma cadeia de texto carrega mais informação sobre a molécula, como o número de anéis aromáticos e de halogênios, do que cinco propriedades globais. Na seed 42, a árvore escolhida acerta 89,7%, dentro da faixa de 88,6% a 89,9% observada nas 10 seeds.

6.3. Profundidade e poda

A busca em grade escolheu a entropia como critério e nenhum limite de profundidade nos seis cenários, e só ativou a poda quando os atributos eram apenas os descritores: com cerca de 22 mil linhas de treino, a regra de parada da própria árvore já fica perto do ideal. A Figura 3a mostra o motivo. A acurácia de treino chega a 100% na profundidade 25, enquanto a de validação estaciona em torno de 87% a partir da profundidade 16. A poda por custo-complexidade (Figura 3b) reduz a árvore de 2.054 para 899 folhas com $\alpha = 10^{-4}$ sem perder acurácia de validação (87,0% para 87,2%); acima de 10^{-3} a poda passa a custar acurácia, e com $\alpha = 10^{-2}$ sobram 8 folhas e 66,5%.

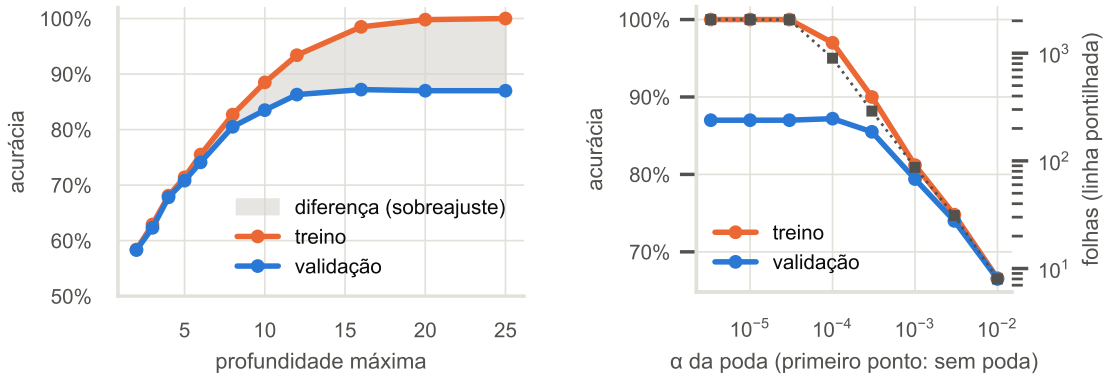


Figura 3. Acurácia de treino e de validação (seed 42, divisão agrupada, 17 atributos). (a) Por profundidade máxima. (b) Por α da poda, com o número de folhas na escala da direita (linha pontilhada); o primeiro ponto é $\alpha = 0$.

6.4. O que a árvore aprendeu

A árvore escolhida tem 1.854 folhas e 24 níveis, grande demais para ser desenhada. As primeiras camadas, porém, são legíveis (Figura 4). A raiz divide por TPSA (limiar de 67,9) e o ramo de TPSA baixa tem 69% de DRD2, como a análise exploratória antecipava. Em seguida vêm o número de átomos aromáticos, um atributo do SMILES, e depois HBD, número de anéis, comprimento do SMILES e número de halogênios. Descritores e contagens se misturam já no topo. A Figura 5 confirma o quadro: TPSA e o número de átomos aromáticos lideram nas duas medidas de importância, seguidos por HBD e por um bloco de contagens (átomos de N, halogênios, estereoquímica, anéis) acima de LogP e HBA. A importância por permutação, medida no teste, dá mais peso às contagens do que a de impureza.

6.5. Erros e limites da árvore

Entre as classes, BACE1 e DRD2 são as mais fáceis (F1 de 90,9% e 90,4%), seguidas de EGFR (89,2%) e HDAC1 (86,6%), a mais difícil. Na seed 42, o par HDAC1 $\leftrightarrow$ EGFR, nos

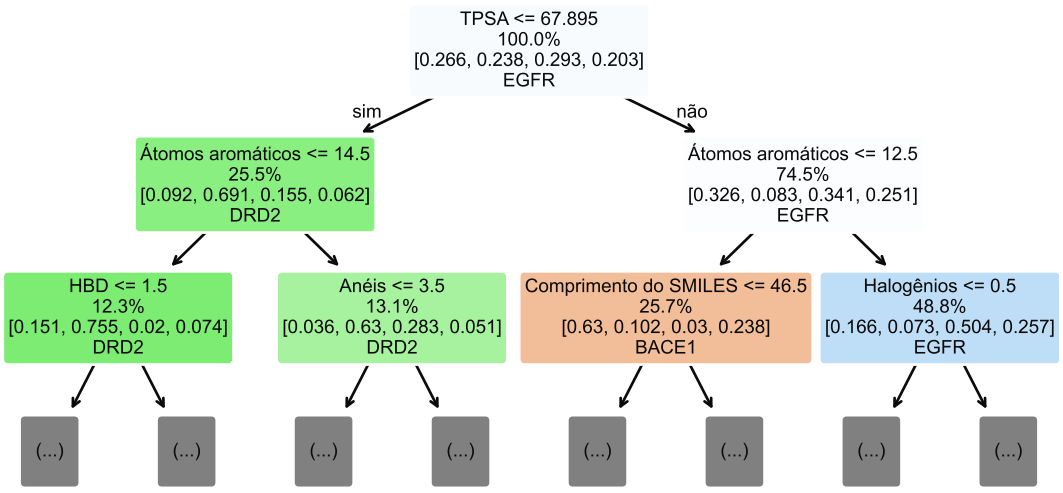


Figura 4. Três primeiras camadas da árvore escolhida (seed 42, divisão agrupada, 17 atributos). Cada nó mostra a regra de divisão, a fração das moléculas de treino que chega a ele, a proporção de cada classe (na ordem BACE1, DRD2, EGFR e HDAC1) e a classe majoritária, que também define a cor. A aresta "sim" leva às moléculas que satisfazem a regra; os nós cinza marcam subárvores omitidas.

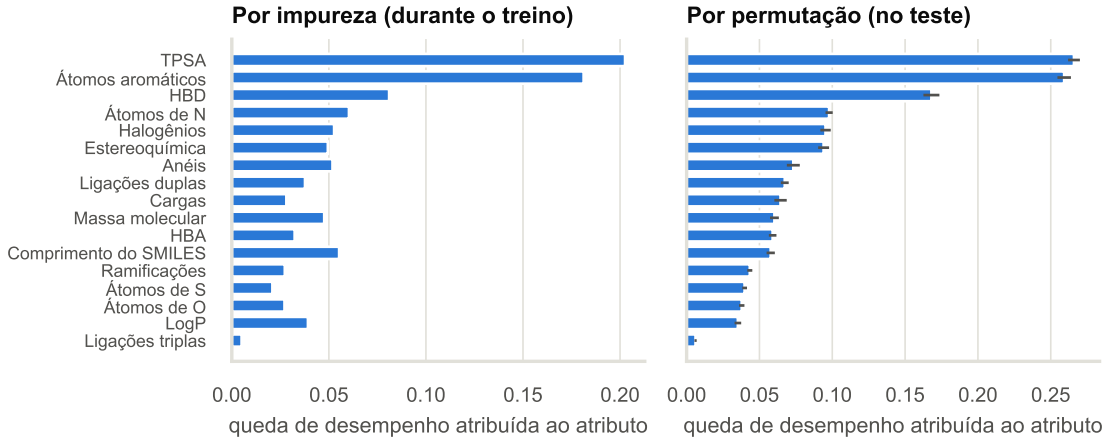


Figura 5. Importância dos atributos da árvore escolhida (seed 42). À esquerda, a redução de impureza acumulada nos nós que usam o atributo, durante o treino. À direita, a queda de acurácia no teste quando os valores do atributo são embaralhados (permutação).

dois sentidos, soma 28,7% dos 568 erros (Figura 6a), e 7,9% das moléculas de HDAC1 viram EGFR. Os erros não ocupam uma região do espaço de atributos: nenhum dos 17 atributos desloca a mediana entre acertos e erros em mais de meio intervalo interquartil. Entre seis exemplos de HDAC1 lidos como EGFR, dois contêm a mesma subestrutura, o grupo de átomos C(=O)NO. A árvore não a distingue: contagens de caracteres dizem quantos oxigênios e nitrogênios existem, mas não como estão ligados.

A árvore também não sabe quando erra. Sem poda, toda folha é pura, então a

probabilidade de classe estimada pela árvore é 100% nas 5.496 previsões de teste, embora 10,3% estejam erradas. A curva de aprendizado (Figura 6b) mostra a outra limitação: o treino fica em 100% e a validação sobe de 61,5% (879 linhas) para 87,0% (17.584) sem se achatar, de modo que mais moléculas provavelmente renderiam mais acurácia.

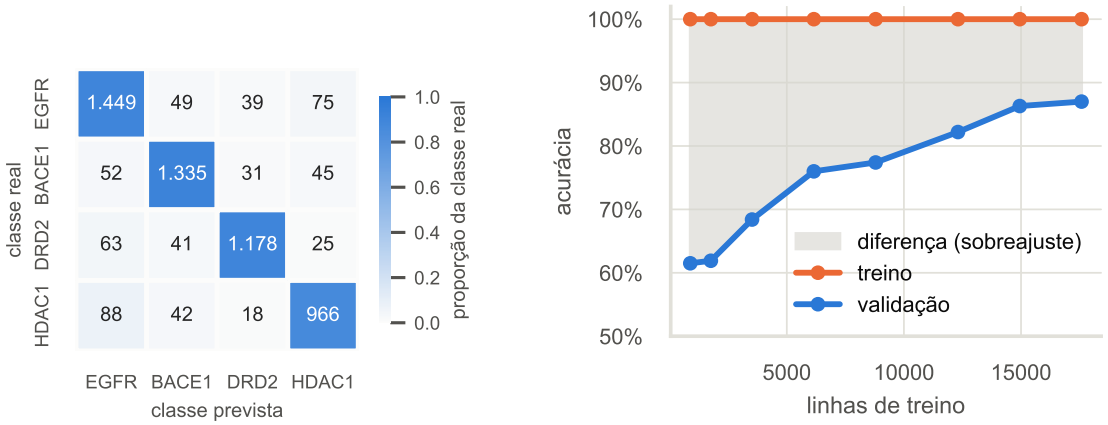


Figura 6. Seed 42, divisão agrupada, 17 atributos. (a) Matriz de confusão no teste: cor pela proporção da classe real, número em contagem. (b) Curva de aprendizado: acurácia por tamanho do conjunto de treino.

6.6. Comparação com modelos de referência

A Tabela 4 situa a árvore entre um piso e um teto. Responder sempre EGFR, a classe majoritária, dá 29,3% de acurácia, que é a proporção de EGFR na base. A Random Forest [Breiman 2001] chega a 95,2 $\pm$ 0,3% e o *gradient boosting* a 94,8 $\pm$ 0,3%, enquanto a árvore única acerta 89,4 $\pm$ 0,4%: a Random Forest supera a árvore em 6,4% (relativo). Esse ganho é o preço da interpretabilidade: a árvore responde por que uma molécula foi classificada como DRD2 com um caminho de perguntas sobre TPSA e contagens, enquanto os conjuntos não têm regras legíveis.

Tabela 4. Árvore e modelos de referência na divisão agrupada, com os 17 atributos (média $\pm$ desvio em 10 seeds).

Modelo	Acurácia (%)	F1 macro (%)
Classe majoritária (EGFR)	29,3 $\pm$ 0,0	11,3 $\pm$ 0,0
Árvore de decisão	89,4 $\pm$ 0,4	89,3 $\pm$ 0,4
Random Forest (300 árvores)	95,2 $\pm$ 0,3	95,1 $\pm$ 0,3
Gradient boosting (histogramas)	94,8 $\pm$ 0,3	94,7 $\pm$ 0,3

7. Limitações

O agrupamento por descritores idênticos não cobre famílias de moléculas muito parecidas entre si, que continuam espalhadas entre treino e teste; as contagens de SMILES permitem decorar essas famílias. Dividir por família (esqueleto molecular) controlaria isso, mas exige uma biblioteca de química. Por isso a acurácia de 89,4% ainda é otimista para moléculas realmente novas.

O modelo escolhe sempre uma entre quatro classes: não existe a opção "nenhuma das quatro", então ele não sabe dizer que uma molécula não pertence a nenhum dos alvos. As 10 seeds variam o sorteio da divisão, mas os dados são os mesmos, de modo que o desvio padrão não mede a incerteza para dados novos, e não há validação externa. A Random Forest e o *gradient boosting* usam hiperparâmetros padrão, e o teto que representam pode estar subestimado. Por fim, as 238 moléculas sem descritores (0,86%) foram descartadas, em sua maioria muito grandes, e as probabilidades da árvore não são calibradas.

8. Conclusão e trabalhos futuros

Reconstruímos do ChEMBL_37 uma base de 27.714 moléculas, cada uma associada a um de quatro alvos (EGFR, BACE1, DRD2 e HDAC1), e treinamos uma árvore de decisão para prever o alvo. Com divisão agrupada, os cinco descritores físico-químicos dão acurácia de 77,1%; acrescentar 12 contagens de caracteres do SMILES leva a 89,4 $\pm$ 0,4% (ganho relativo de 16%), e as contagens sozinhas já chegam a 87,6%. A divisão aleatória superestima o resultado em 1,5% a 5,3% (relativo) porque cerca de um quarto das moléculas de teste tem gêmea de descritores no treino. TPSA e o número de átomos aromáticos são os atributos mais importantes, e o par HDAC1–EGFR concentra 28,7% dos erros. A Random Forest chega a 95,2%, 6,4% acima da árvore, que em troca oferece regras legíveis.

Quatro caminhos seguem do que foi visto. Representações estruturais da molécula (*fingerprints*), calculadas com uma biblioteca de química, enxergariam subestruturas como o grupo C(=O)NO, que as contagens não veem. Uma divisão por esqueleto molecular daria uma estimativa menos otimista para moléculas novas. A curva de aprendizado ainda sobe, o que sugere buscar mais dados no ChEMBL, com outros alvos ou um limiar de pChEMBL mais baixo. Por fim, podar a árvore ou usar um conjunto de árvores daria probabilidades calibradas.

Referências

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth International Group, Belmont, CA.

Davies, M., Nowotka, M., Papadatos, G., Dedman, N., Gaulton, A., Atkinson, F., Bellis, L., and Overington, J. P. (2015). ChEMBL web services: streamlining access to drug discovery data and utilities. *Nucleic Acids Research*, 43(W1):W612–W620.

Ertl, P., Rohde, B., and Selzer, P. (2000). Fast calculation of molecular polar surface area as a sum of fragment-based contributions and its application to the prediction of drug transport properties. *Journal of Medicinal Chemistry*, 43:3714–3717.

Gaulton, A. et al. (2012). ChEMBL: a large-scale bioactivity database for drug discovery. *Nucleic Acids Research*, 40(D1):D1100–D1107.

Kapoor, S. and Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804.

Keiser, M. J., Roth, B. L., Armbruster, B. N., Ernsberger, P., Irwin, J. J., and Shoichet, B. K. (2007). Relating protein pharmacology by ligand chemistry. *Nature Biotechnology*, 25(2):197–206.

Lipinski, C. A., Lombardo, F., Dominy, B. W., and Feeney, P. J. (2001). Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. *Advanced Drug Delivery Reviews*, 46(1–3):3–26.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Sheridan, R. P. (2013). Time-split cross-validation as a method for estimating the goodness of prospective prediction. *Journal of Chemical Information and Modeling*, 53(4):783–790.

Weininger, D. (1988). SMILES, a chemical language and information system. 1. introduction to methodology and encoding rules. *Journal of Chemical Information and Computer Sciences*, 28(1):31–36.

xjoannax88 (2026). MultiTarget Bioactivity ChEMBL. Kaggle, versão 17. `https://www.kaggle.com/datasets/xjoannax88/multitarget-bioactivity-chembl`.

Zdrazil, B. et al. (2024). The ChEMBL database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods. *Nucleic Acids Research*, 52(D1):D1180–D1192.