Classificação de alvos proteicos a partir de descritores moleculares do ChEMBL com árvores de decisão

Bernan R. do Nascimento · Paulo E. R. Araujo · Thiago R. P. de Carvalho

Universidade Federal do Piauí (UFPI) · PPGCC010 – Aprendizagem de Máquina (2026.2)

Prof. Vinicius Ponte Machado

Prever o alvo de uma molécula é mais difícil do que parece

4 alvos · 27.714 moléculas

EGFR
8.108 moléculas
29,3%

BACE1
7.344 moléculas
26,5%

DRD2
6.650 moléculas
24,0%

HDAC1
5.612 moléculas
20,2%

Responder sempre EGFR, a classe mais frequente, acerta 29,3%: esse é o piso.

Três desafios

1. **Base de partida quebrada**
   o arquivo do Kaggle não bate com a própria descrição

2. **Descritores fracos**
   um descritor sozinho acerta no máximo 45,1%

3. **Teste contaminado**
   25,8% das moléculas de teste têm uma gêmea no treino

SBC
Sociedade Brasileira de Computação

A base do Kaggle estava quebrada, então reconstruímos do ChEMBL

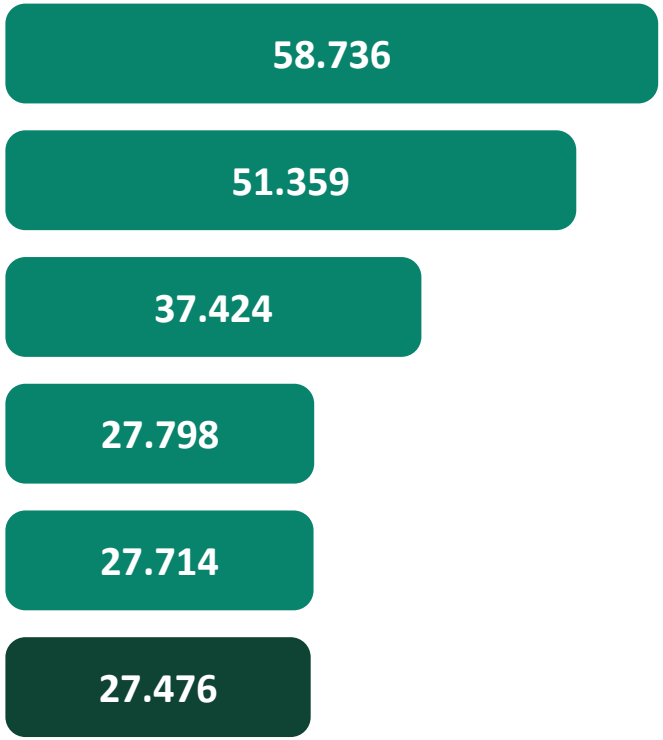
Arquivo do Kaggle

1.333
linhas (a página descreve 8.711)

0
moléculas de EGFR

95,5%
das linhas são DRD2

Reconstrução a partir do ChEMBL_37



ChEMBL_37, extraído em 24/10/2026

A base traz 5 descritores por molécula, calculados da estrutura

Exemplo: molécula CHEMBL1085117 (HDAC1)

Os cinco valores vêm prontos no ChEMBL e são tudo que o modelo vê de cada molécula

Massa molecular

432,53

daltons

Soma das massas dos átomos: mede o tamanho da molécula

LogP

1,88

sem unidade

Quanto a molécula prefere gordura a água

HBA

7

átomos aceptores

Átomos (em geral N e O) que podem receber uma ligação de hidrogênio

HBD

4

grupos doadores

Hidrogênios ligados a N ou O, que podem doar a ligação

TPSA

128,59

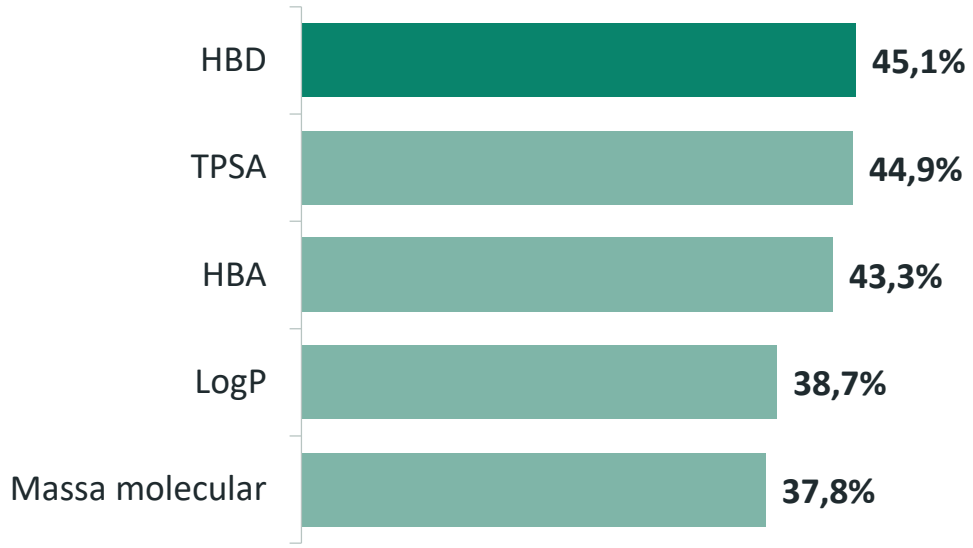
Å²

Área ocupada pelos átomos polares (N, O e seus hidrogênios)

No próximo slide, a mesma molécula aparece como texto (SMILES)

Cinco descritores não bastam; contar o SMILES ajuda

Acurácia de uma árvore com um só descritor



Piso: responder sempre EGFR acerta 29,3%

12 atributos a partir do SMILES

SMILES: texto que descreve a estrutura da molécula

```
CCN(CC)CCn1cnc2cc(C(=O)NC(=O)NCCCCCC(=O)NO)ccc21
```

Uma molécula real da base (HDAC1)

48 comprimento	**6** átomos de N	**4** átomos de O
2 anéis	**9** átomos aromáticos	**3** ligações duplas

6 dos 12 atributos; contar caracteres não analisa a estrutura

A divisão aleatória deixa o teste ver a resposta

Divisão aleatória



Gêmeas dos dois lados: acertar o teste vira lembrar o treino

Divisão agrupada



Gêmeas sempre do mesmo lado: o teste exige generalizar

Mesma cor: moléculas com os mesmos 5 descritores (gêmeas) · esquema ilustrativo

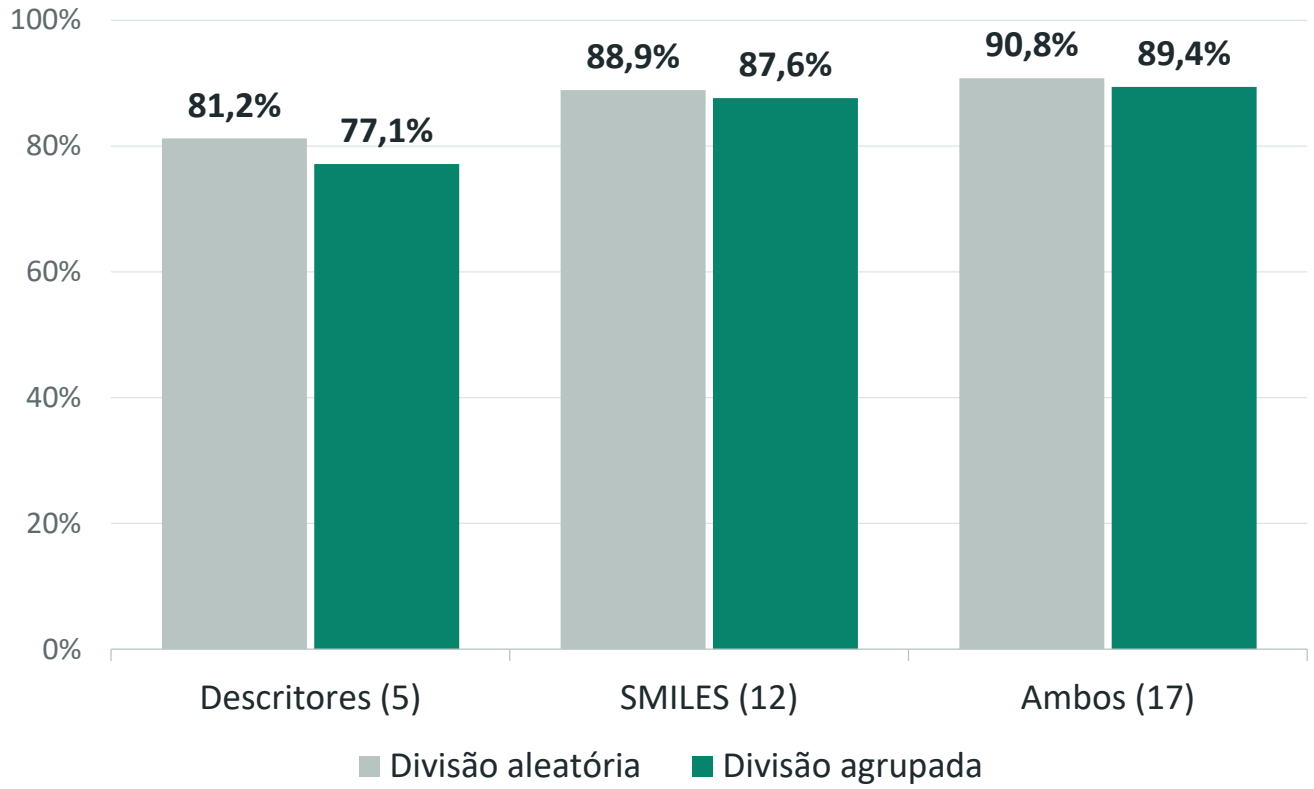
25,8%

das moléculas de teste têm gêmea no treino (divisão aleatória)

3 conjuntos de atributos × 2 divisões = 6 cenários, repetidos com 10 seeds

Contar o SMILES eleva a acurácia em 16%

Acurácia no teste por conjunto de atributos



+16%

ganho relativo ao juntar descritores e contagens de SMILES (divisão agrupada: 77,1% → 89,4%)

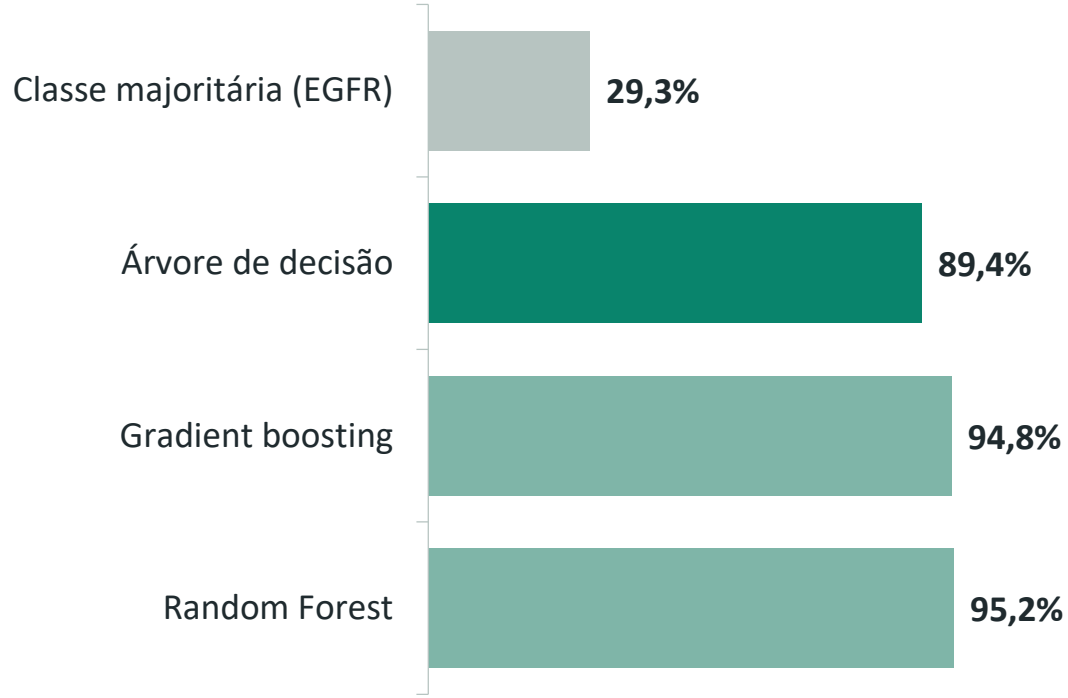
Quanto a divisão aleatória superestima a acurácia

5,3%	1,5%	1,5%
descritores	SMILES	ambos

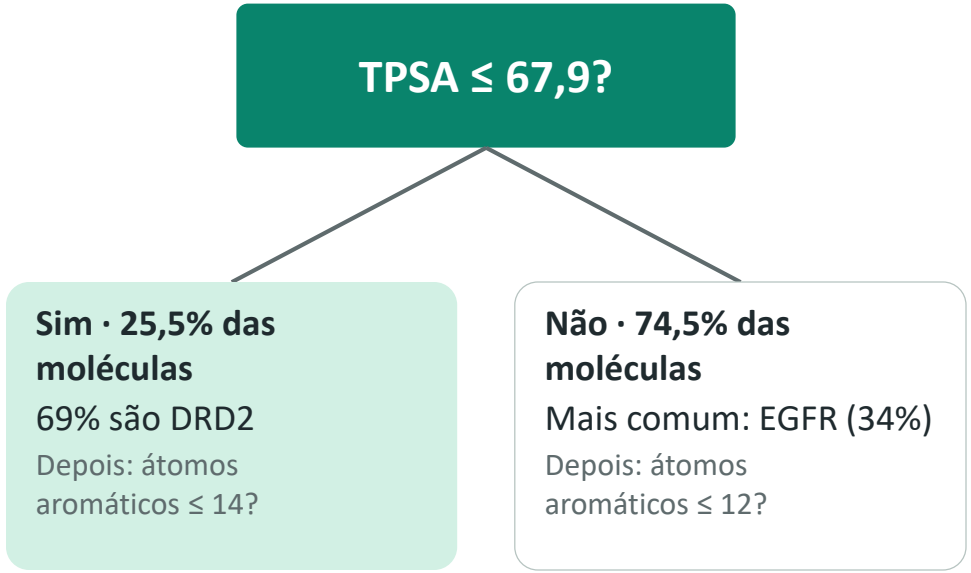
Média de 10 seeds; desvio padrão de até 0,8%

A Random Forest supera a árvore em 6,4%, mas só a árvore tem regras legíveis

Acurácia na divisão agrupada (média de 10 seeds)



Primeiros níveis da árvore



A árvore completa tem 1.854 folhas. TPSA e átomos aromáticos lideram a importância dos atributos.

A árvore erra entre HDAC1 e EGFR e não sabe que errou

Matriz de confusão no teste (seed 42)

	EGFR	BACE1	DRD2	HDAC1
EGFR	**1.449**	49	39	75
BACE1	52	**1.335**	31	45
DRD2	63	41	**1.178**	25
HDAC1	88	42	18	**966**

Linhas: classe real · colunas: classe prevista; cor pela proporção da linha

28,7%

dos erros são HDAC1 ↔ EGFR

Exemplo: HDAC1 lido como EGFR

`CCN(CC)CCn1cnc2cc(C(=O)NC(=O)NCCCCCC(=O)NO)ccc21`

Contar caracteres não distingue o grupo de átomos C(=O)NO

100%

de confiança nas 5.496 previsões, com 10,3% erradas

Conclusões e próximos passos

89,4%

acurácia da árvore na divisão agrupada, com 17 atributos

+16%

ganho relativo ao contar o SMILES, sobre só os descritores

1,5% a 5,3%

quanto a divisão aleatória superestima a acurácia

Limites

- O agrupamento cobre só descritores idênticos, não famílias de moléculas parecidas
- O modelo sempre escolhe uma de 4 classes
- Não há validação externa

Próximos passos

- Representações estruturais da molécula
- Divisão por esqueleto molecular
- Mais dados e probabilidades calibradas

Código e dados: github.com/pumba-dev/machine-learning-practice · **Perguntas?**