Classificação de alvos proteicos a partir de descritores moleculares do ChEMBL com árvores de decisão

Bernan R. do Nascimento · Paulo E. R. Araujo · Thiago R. P. de Carvalho

Universidade Federal do Piauí (UFPI)

PPGCC010 – Aprendizagem de Máquina (2026.2) · Prof. Vinicius Ponte Machado

Prever o alvo de uma molécula é mais difícil do que parece

4 alvos · 27.714 moléculas

- **EGFR**
  8.108 moléculas
  29,3%
- **BACE1**
  7.344 moléculas
  26,5%
- **DRD2**
  6.650 moléculas
  24,0%
- **HDAC1**
  5.612 moléculas
  20,2%

Responder sempre EGFR acerta 29,3%: esse é o piso.

Três desafios

1. **Base de partida quebrada**
   o arquivo do Kaggle não bate com a própria descrição
2. **Descritores fracos**
   um descritor sozinho acerta no máximo 45,1%
3. **Teste contaminado**
   25,8% das moléculas de teste têm uma gêmea no treino

A base do Kaggle estava quebrada, então reconstruímos do ChEMBL

Arquivo do Kaggle

1.333

linhas (descritas: 8.711)

0

moléculas de EGFR

95,5%

das linhas são DRD2

Reconstrução do ChEMBL_37 (24/10/2026)

58.736	medições de ligação
51.359	sem duplicata ou SMILES vazio
37.424	pares molécula-alvo (mediana)
27.798	pares com pChEMBL ≥ 6
27.714	moléculas de alvo único (−42)
27.476	com os 5 descritores (−238)

A base traz 5 descritores por molécula, calculados da estrutura

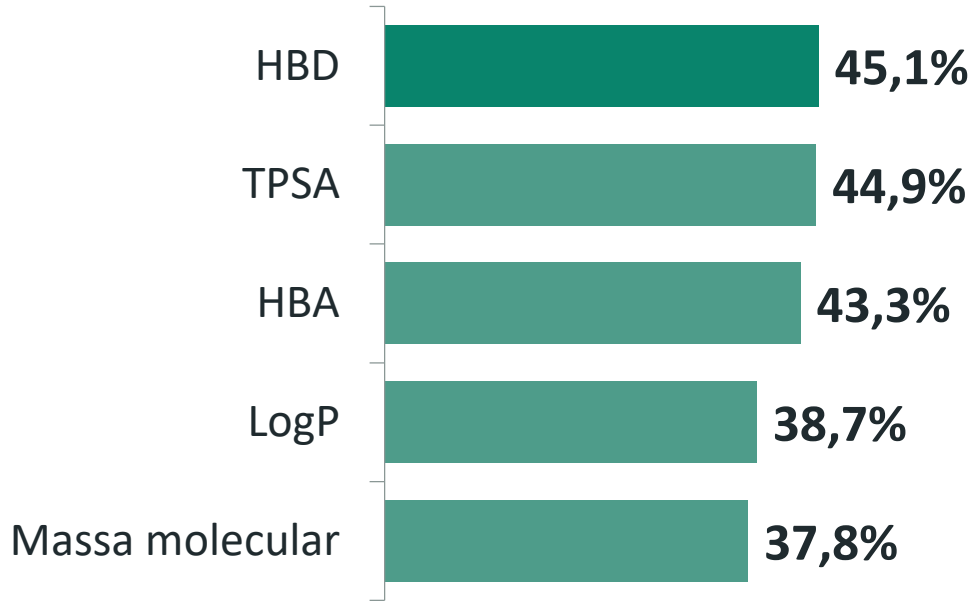
Exemplo: molécula CHEMBL1085117 (HDAC1)

Valores do ChEMBL; no próximo slide, a mesma molécula como texto

Massa molecular	**432,53**	dáltons	Soma das massas dos átomos
LogP	**1,88**	sem unidade	Quanto prefere gordura a água
HBA	**7**	átomos	Aceitam ligação de hidrogênio
HBD	**4**	grupos	Doam ligação de hidrogênio
TPSA	**128,59**	Å²	Área ocupada por átomos polares

Cinco descritores não bastam; contar o SMILES ajuda

Acurácia com um só descritor



Piso: sempre EGFR = 29,3%

12 atributos do SMILES

Texto que descreve a molécula

```
CCN(CC)CCn1cnc2cc(C(=O)N
C(=O)NCCCCCC(=O)NO)ccc21
```

48 comprimento	**6** átomos de N	**4** átomos de O
2 anéis	**9** aromáticos	**3** ligações duplas

A divisão aleatória deixa o teste ver a resposta

Divisão aleatória



Gêmeas dos dois lados: acertar o teste vira lembrar o treino

Divisão agrupada



Gêmeas sempre do mesmo lado: o teste exige generalizar

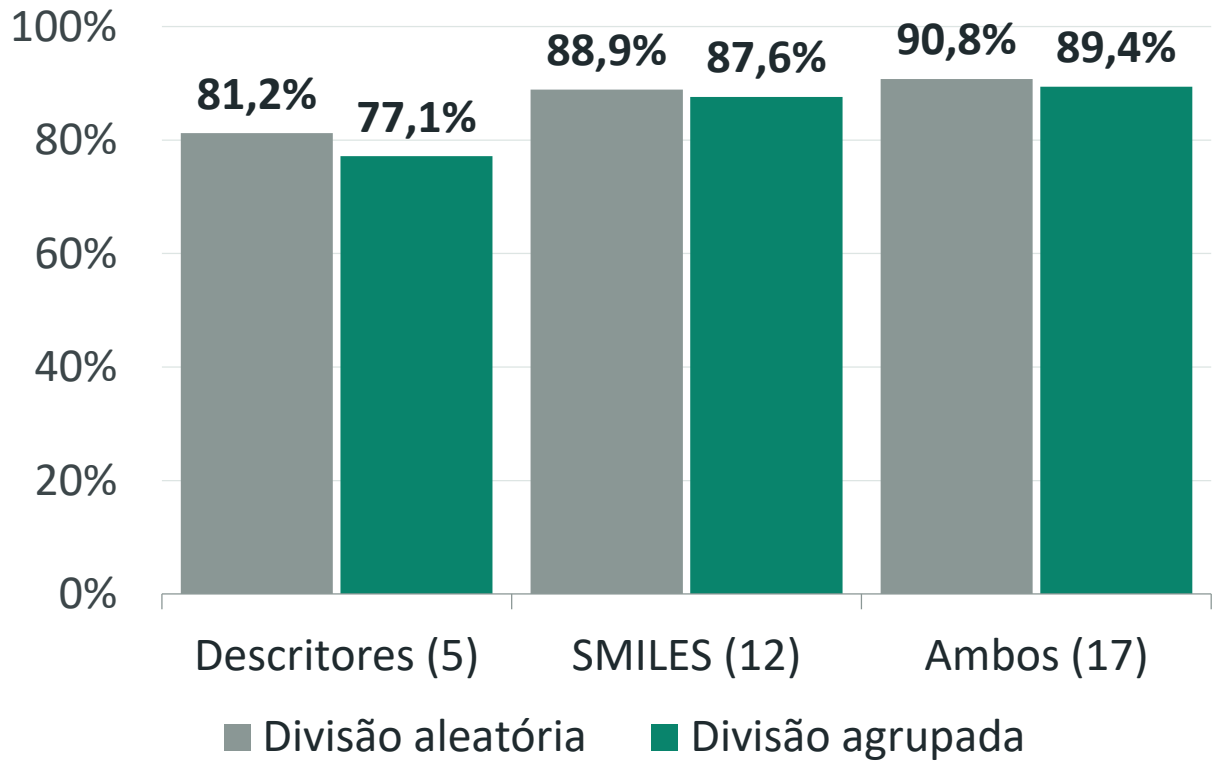
Mesma cor: gêmeas (mesmos 5 descritores) · esquema ilustrativo

25,8% do teste tem gêmea no treino (aleatória)

3 conjuntos × 2 divisões = 6 cenários repetidos com 10 seeds

Contar o SMILES eleva a acurácia em 16%

Acurácia por conjunto de atributos



+16%

ganho relativo com as contagens de SMILES (77,1% → 89,4%)

Superestimativa da divisão aleatória

5,3% descritores

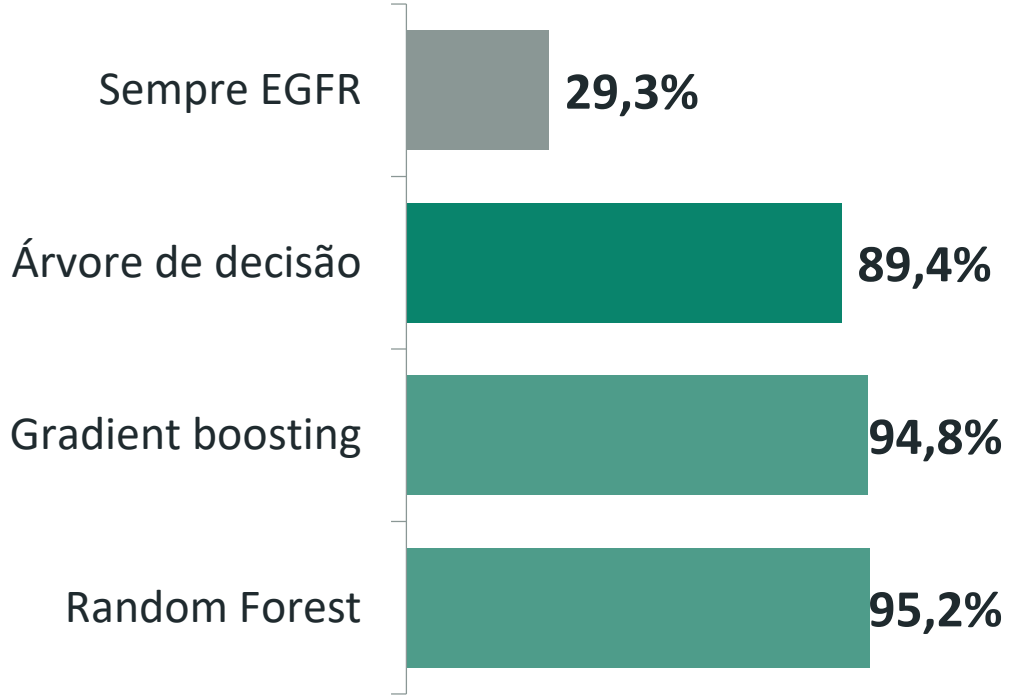
1,5% SMILES

1,5% ambos

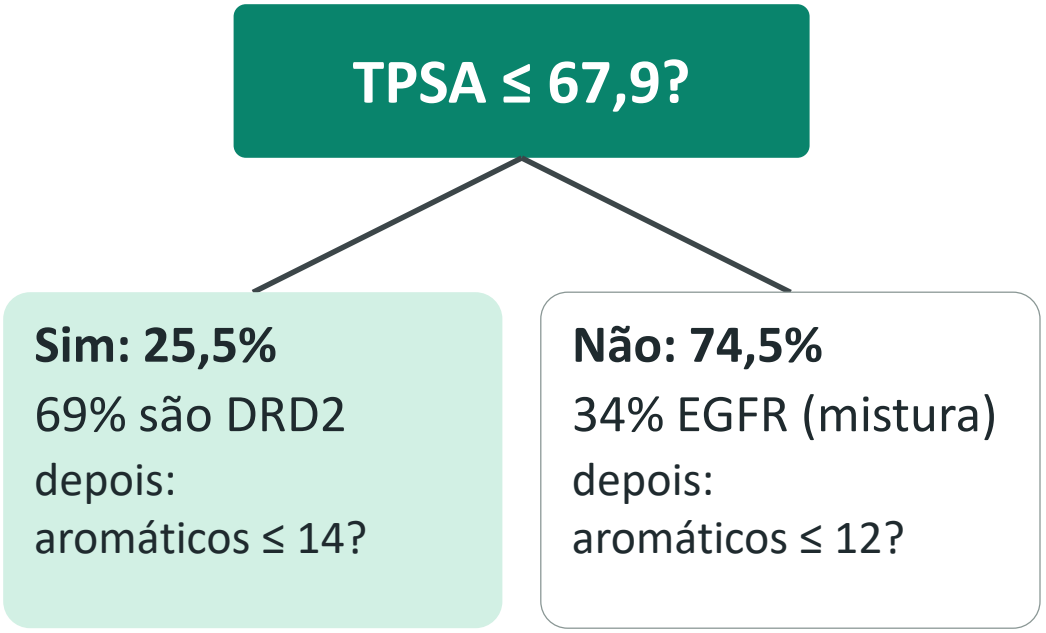
Média de 10 seeds; desvio até 0,8%

A Random Forest supera a árvore em 6,4%, mas só a árvore tem regras legíveis

Acurácia na divisão agrupada



Primeiros níveis da árvore



Árvore completa: 1.854 folhas. TPSA e aromáticos lideram a importância.

A árvore erra entre HDAC1 e EGFR e não sabe que errou

Matriz de confusão no teste (seed 42)

	EGFR	BACE1	DRD2	HDAC1
EGFR	**1.449**	49	39	75
BACE1	52	**1.335**	31	45
DRD2	63	41	**1.178**	25
HDAC1	88	42	18	**966**

Linha: classe real · coluna: prevista

28,7%

dos erros são HDAC1 ↔ EGFR

Por que erra?

Os atributos tirados do SMILES são só contagens e podem não bastar para representar a molécula

100%

de confiança nas 5.496 previsões; 10,3% erradas

Conclusões e limites

89,4%

acurácia da árvore na divisão agrupada, com 17 atributos

+16%

ganho relativo ao contar o SMILES, sobre só os descritores

1,5% a 5,3%

quanto a divisão aleatória superestima a acurácia

Limites

- Agrupa só descritores idênticos, não famílias de moléculas parecidas
- Escolhe sempre uma de 4 classes
- Sem validação externa

Código e dados: github.com/pumba-dev/machine-learning-practice · **Perguntas?**