Árvore de decisão, Random Tree e conjuntos de árvores na classificação de alvos proteicos

Segunda parte: comparação de modelos

Bernan R. do Nascimento · Paulo E. R. Araujo · Thiago R. P. de Carvalho

Universidade Federal do Piauí (UFPI)

PPGCC010 – Aprendizagem de Máquina (2026.2) · Prof. Vinicius Ponte Machado

SBC
Sociedade Brasileira de Computação

Na primeira parte, a árvore de decisão chegou a 89,4%

27.476 moléculas
do ChEMBL, cada uma associada a 1 de 4 proteínas

17 atributos
5 descritores físico-químicos + 12 contagens do SMILES

Divisão agrupada
moléculas gêmeas (mesmos descritores) sempre do mesmo lado

89,4%

acurácia da árvore de decisão, média de 10 seeds

Uma árvore só é o melhor que dá para fazer?

SBC
Sociedade Brasileira de Computação

Quatro modelos feitos da mesma peça: a árvore

Modelo	Árvores	Atributos por nó	Como combina
Árvore de decisão	1	todos	–
Random Tree	1	K sorteados	–
Random Forest	300	K sorteados	voto; cada uma vê uma amostra
Gradient boosting	300	todos	soma; cada uma corrige as anteriores

Destaque: a Random Forest é feita de 300 Random Trees

Mesma régua para todos os modelos

1. **Mesmo treino e teste**
   divisão agrupada, 80% e 20%

2. **Busca de hiperparâmetros**
   validação cruzada agrupada, 5 partes

3. **10 seeds**
   média e desvio de cada modelo

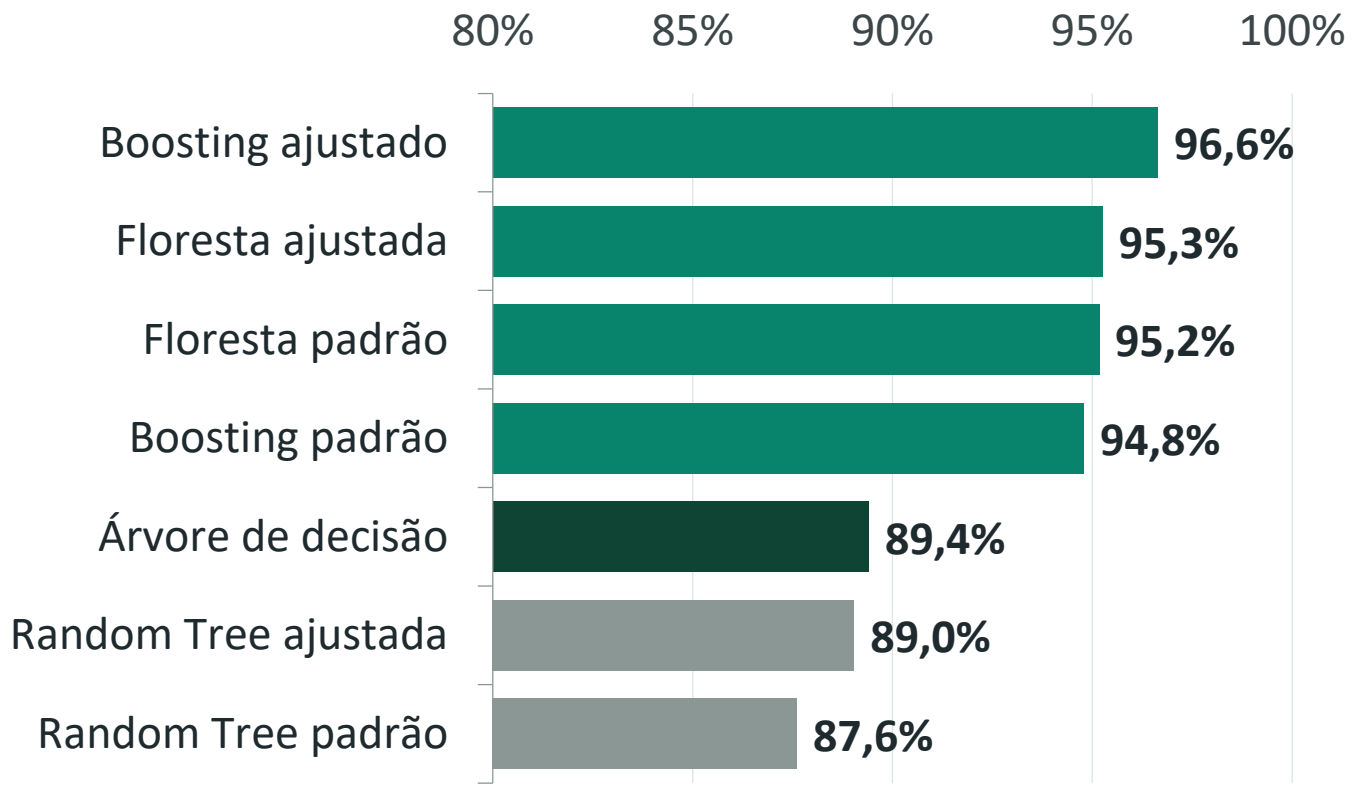
Combinações testadas

Modelo	Busca
Árvore de decisão	72, em 6 cenários
Random Tree	54, em 6 cenários
Random Forest	6, cenário principal
Gradient boosting	9, cenário principal

Desligados: estimativa out-of-bag e parada antecipada. Os dois sorteiam uma validação aleatória e deixariam gêmeas dos dois lados.

Conjuntos ganham de 5% a 7%; a Random Tree perde para a árvore

Acurácia no teste, média de 10 seeds



Eixo a partir de 80%; piso (sempre EGFR): 29,3%

+7,2%

de acurácia: boosting ajustado sobre a árvore

10 de 10

seeds: todo conjunto supera a árvore

–0,4%

de acurácia: Random Tree ajustada contra a árvore

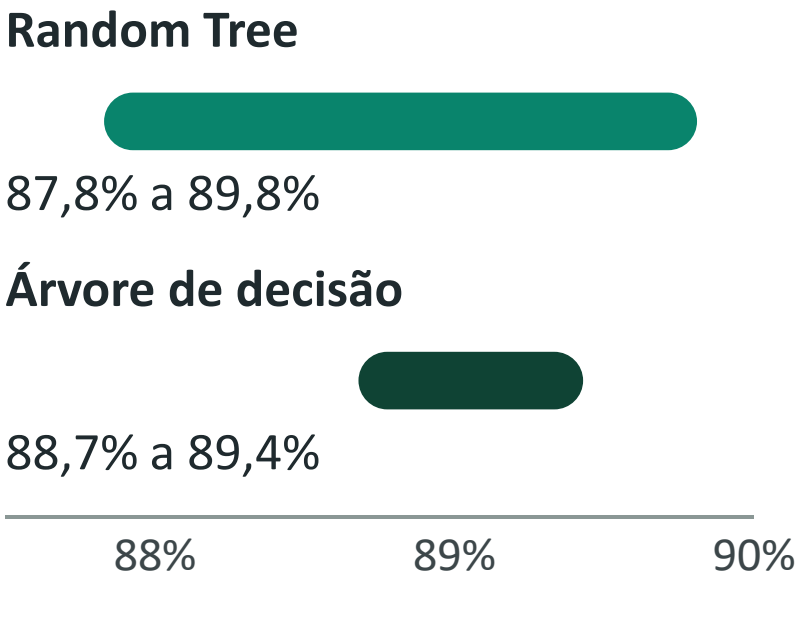
A Random Tree perde em 5 de 6 cenários e varia com a semente

Random Tree menos árvore (10 seeds)

Atributos	Divisão	Diferença
Descritores (5)	aleatória	**–0,7%**
Descritores (5)	agrupada	**–2,0%**
SMILES (12)	aleatória	**0,0%**
SMILES (12)	agrupada	**–0,2%**
Ambos (17)	aleatória	**–0,3%**
Ambos (17)	agrupada	**–0,4%**

Só trocando a semente

mesmos dados e mesma divisão, 50 sementes (seed 42)



Sozinha, a Random Tree perde; 300 delas formam a Random Forest

1 árvore, sem sorteio		1 árvore, com sorteio		300 árvores, com sorteio
88,5% Árvore de decisão	–1,9%	**86,6%** Random Tree	+8,6%	**95,2%** Random Forest

Numa árvore só
o sorteio esconde o melhor corte do nó

Em 300 árvores
o sorteio deixa as árvores diferentes: elas erram em moléculas diferentes e o voto cancela os erros

Seed 42, teste; mesma árvore base; árvore única = média de 10 sementes

Ajustar rende no boosting, não na floresta

Padrão → ajustado (10 seeds)

Random Forest

95,2% → 95,3%

empate

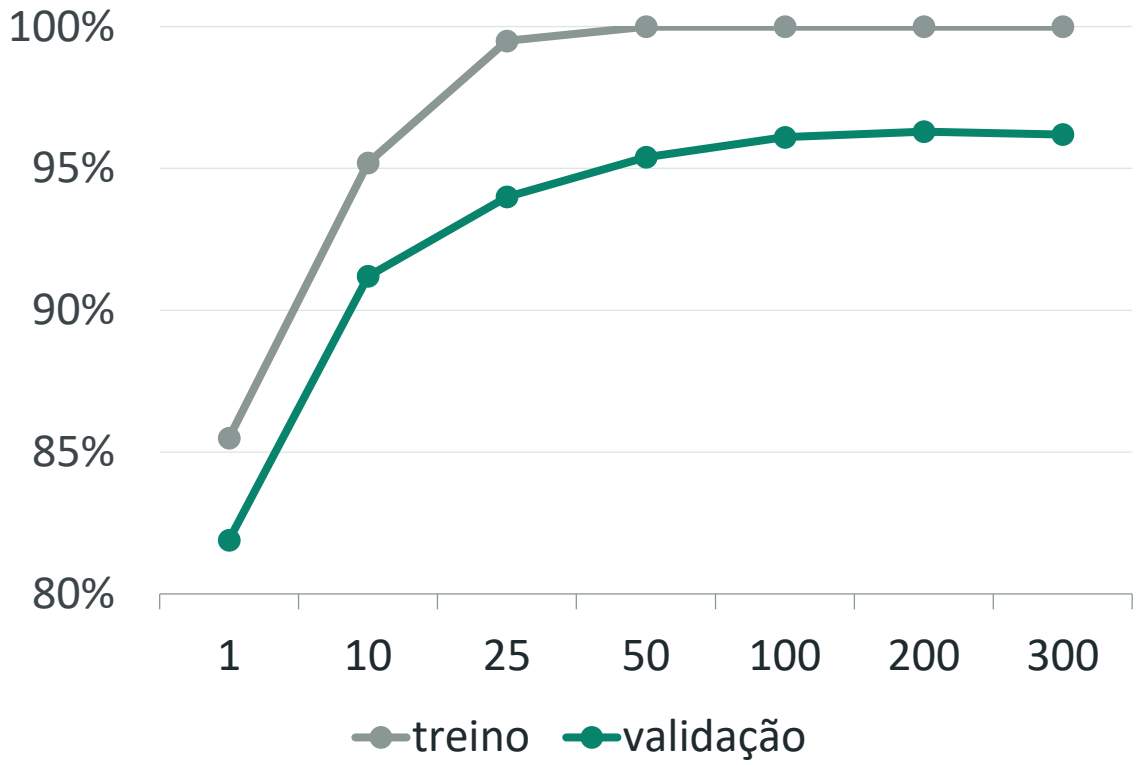
Gradient boosting

94,8% → 96,6%

+1,8%

Boosting: 300 iterações, sem parada antecipada

Boosting por iteração (validação)



Só a Random Forest sabe quando está em dúvida

Modelo	Acurácia	Regras legíveis	Confiança útil?
Árvore de decisão	89,4%	sim	não: 100% em tudo
Random Tree	89,0%	mudam com a semente	não
Random Forest	95,2%	não	**sim: 91% dos erros com ≤ 70%**
Gradient boosting	96,6%	não	pouco: 21% dos erros > 99,9%

Na prática: revisar os 20% de previsões da floresta com confiança ≤ 70% pega 91% dos erros

Conclusões

96,6%

gradient boosting ajustado, o mais preciso

+5,8%

de acurácia: Random Forest, 300 Random Trees juntas

–0,4%

de acurácia: a Random Tree sozinha perde para a árvore

Qual usar

Acertar mais **gradient boosting**	Saber quando duvidar **Random Forest**	Explicar a previsão **árvore de decisão**

Código e dados: github.com/pumba-dev/machine-learning-practice · **Perguntas?**